cricc
Centre de Recerca en Informació, Comunicació i Cultura

Universitat de Barcelona

Guía de *prompting* para modelos de lenguaje: fundamentos, buenas prácticas y técnicas

Rubén Alcaraz-Martínez

Facultat d'Informació i Mitjans Audiovisuals
Universitat de Barcelona
Melcior de Palau, 140
08014 Barcelona

Autor: Rubén Alcaraz-Martínez

Obra distribuida bajo una licencia Creative Commons BY-NC-SA 4.0



Cita recomendada

Alcaraz-Martínez, Rubén (2026). *Guía de prompting para modelos de lenguaje: fundamentos, buenas prácticas y técnicas*. Barcelona: Universitat de Barcelona. https://doi.org/10.5281/zenodo.19605053

Sobre el autor

Rubén Alcaraz Martínez es doctor en Ingeniería y Tecnologías de la Información, máster en Gestión de Contenidos Digitales y diplomado en Biblioteconomía y Documentación. Es profesor del Departamento de Biblioteconomía, Documentación y Comunicación Audiovisual de la Universidad de Barcelona donde imparte docencia en el grado en Gestión de Información y Documentación Digital, el máster en Gestión de Contenidos Digitales, el máster en Humanidades Digitales y el máster en Bibliotecas Públicas. Es miembro del grupo de innovación docente consolidado Adaptabit, dedicado a la investigación en accesibilidad digital y forma parte del Centro de Investigación en Información, Comunicación y Cultura (CRICC).

ORCID: https://orcid.org/0000-0002-7185-0227
Contacto: ralcaraz@ub.edu

Resumen

Este informe introduce recoge múltiples estrategias, métodos y técnicas orientadas al uso de modelos de lenguaje de forma más controlada y fiable. En primer lugar, se introducen los conceptos básicos y, a continuación, se reúnen buenas prácticas para redactar y estructurar instrucciones (claridad, contexto, restricciones, formato de salida), incluyendo un apartado de sintaxis (cómo formular, delimitar y especificar el output), además de secciones específicas sobre cuestiones éticas y vinculadas a la privacidad. El núcleo del informe es una clasificación de técnicas de *prompting* por finalidad: (1) razonamiento y resolución estructurada de problemas; (2) fiabilidad y verificación; (3) metacognición y autorregulación; (4) contexto y dinámica conversacional; (5) control del objetivo y de la salida; (6) código, herramientas y formalización; (7) dimensiones de estilo/afectividad; (8) multimodalidad e interdisciplinariedad, y (9) creatividad y generación abierta.

Palabras clave

Modelos de lenguaje, LLM, Prompts, Ingeniería de prompts, Diseño de prompts.

Resum

Aquest informe recull múltiples estratègies, mètodes i tècniques orientades a l'ús de models de llenguatge d'una manera més controlada i fiable. En primer lloc, s'hi presenten els conceptes bàsics i, tot seguit, s'hi apleguen bones pràctiques per redactar i estructurar instruccions (claredat, context, restriccions i format de sortida). També inclou un apartat de sintaxi (com formular, delimitar i especificar la sortida), a més de seccions específiques sobre qüestions ètiques i relacionades amb la privacitat. El nucli de l'informe és una classificació de tècniques de *prompting* segons la finalitat: (1) raonament i resolució estructurada de problemes; (2) fiabilitat i verificació; (3) metacognició i autoregulació; (4) context i dinàmica conversacional; (5) control de l'objectiu i de la sortida; (6) codi, eines i formalització; (7) dimensions d'estil/afectivitat; (8) multimodalitat i interdisciplinarietat, i (9) creativitat i generació oberta.

Paraules clau

Models de llenguatge, LLM, Prompts, Enginyeria de prompts, Disseny de prompts.

Abstract

This report brings together multiple strategies, methods and techniques aimed at using language models in a more controlled and reliable manner. First, it introduces the foundational concepts and then compiles good practices for drafting and structuring instructions (clarity, context, constraints and output format). It also includes a section on syntax (how to formulate, delimit and specify the output), as well as dedicated sections on ethical issues and privacy-related matters. The core of the report is a classification of prompting techniques by purpose: (1) reasoning and structured problem-solving; (2) reliability and verification; (3) metacognition and self-regulation; (4) context and conversational dynamics; (5) control of the objective and the output; (6) code, tools and formalisation; (7) stylistic/affective dimensions; (8) multimodality and interdisciplinarity; and (9) creativity and open-ended generation.

Keywords

Language models, LLM, Prompts, Prompt engineering, Prompt design.

Sumario

1. Introducción 6

1.1. Qué es un *prompt* 7

1.2. Qué es la ingeniería de *prompts* 8

2. Buenas prácticas en materia de *prompting* 10

2.1. Buenas prácticas generales orientadas a la redacción y estructuración de los *prompts* 10

2.2. Sintaxis 16

2.3. Seguridad 18

2.4. Privacidad y datos personales 19

2.5. Cuestiones éticas 20

2.6. Control de sesgos 23

2.7. Uso responsable y sostenible 25

3. Clasificación y ejemplificación de las técnicas de *prompting* 26

3.1. Razonamiento y resolución estructurada de problemas 28

3.2. Fiabilidad y verificación 40

3.3. Metacognición y autorregulación 45

3.4. Contexto y dinámica conversacional 46

3.5. Control del objetivo y de la salida 48

3.6. Código, herramientas y formalización 51

3.7. Dimensión afectiva y estilística 51

3.8. Multimodalidad e interdisciplinariedad 52

3.9. Creatividad y generación abierta 53

Recomendaciones finales 55

Conclusiones 55

Referencias 57

1. Introducción

Este informe tiene como objetivo sistematizar y presentar estrategias, métodos y técnicas de *prompting* para el uso de modelos de lenguaje de forma más controlada, fiable y responsable, proporcionando un marco aplicable a contextos académicos y profesionales. También poner sobre la mesa diversas cuestiones éticas, así como criterios de gobernanza y buenas prácticas. En particular, en materia de privacidad y protección de datos, control y mitigación de sesgos, transparencia y trazabilidad del uso, seguridad y prevención de usos indebidos, y uso razonable y sostenible.

Los modelos de lenguaje de gran escala, grandes modelos de lenguaje, o modelos extensos de lenguaje (*large language models*, LLM) han modificado de manera sustancial el panorama del aprendizaje automático (Zhao *et al.*, 2023a). Este cambio responde, en buena medida, a los avances derivados de la incorporación de redes neuronales y de técnicas de aprendizaje profundo (*deep learning*) en el ámbito del procesamiento del lenguaje natural (*natural language processing*, NLP), que han permitido a estos modelos aprender a partir de volúmenes masivos de datos y, en consecuencia, adaptarse a un abanico mucho más amplio de tareas (Petroni *et al.*, 2019; Brown *et al.*, 2020).

Un hito decisivo en esta trayectoria fue la introducción de la arquitectura *transformer*[1] (Vaswani *et al.*, 2017), que estableció los fundamentos para el desarrollo de modelos progresivamente más complejos y con mayor capacidad. Con posterioridad, la irrupción de modelos como BERT (Devlin *et al.*, 2018) y GPT (Radford *et al.*, 2019) evidenció el potencial del preentrenamiento sobre grandes volúmenes de datos, complementado por un proceso de ajuste fino (*fine-tuning*)[2] orientado a optimizar el rendimiento en tareas concretas.

Esta evolución tecnológica propició la aparición de un tipo específico de LLM, conocidos como variantes conversacionales de transformadores decodificadores unidireccionales (*conversational decoder-only transformer variants)* (Vaswani *et al.*, 2017), entre los que se encuentran modelos como GPT (Brown *et al.*, 2020; Ouyang *et al.*, 2022), LaMDA (Thoppilan *et al.*, 2022), PaLM (Chowdhery *et al.*, 2023), LLaMA (Touvron *et al.*, 2023) y Mistral (Jiang *et al.*, 2023).

Estos modelos destacan por su elevada capacidad para procesar, generar e interpretar lenguaje natural, lo que ha motivado su adopción en una amplia diversidad de dominios. Entre ellos se incluyen ámbitos tan dispares como las finanzas (Wu *et al.*, 2023), la programación (Xu *et al.*, 2022), el contexto educativo (Kasneci *et al.*, 2023) o la atención sanitaria (Thirunavukarasu *et al.*, 2023).

---

[1] Arquitectura de redes neuronales basada en mecanismos de atención (*self-attention*) que permiten modelar dependencias entre elementos de una secuencia sin recurrir a estructuras recurrentes o convolucionales. Esta aproximación mejora la eficiencia computacional y la capacidad de capturar relaciones a largo plazo en tareas de procesamiento del lenguaje natural.

[2] Proceso mediante el cual un modelo previamente preentrenado sobre grandes volúmenes de datos generales se adapta a una tarea específica mediante un nuevo entrenamiento sobre un conjunto de datos más reducido y especializado, ajustando sus parámetros para optimizar el rendimiento en un dominio o problema concreto.

Por otra parte, su naturaleza conversacional, junto con la popularización de interfaces basadas en chat como ChatGPT (Brown *et al.*, 2020; Yang *et al.*, 2024a), ha facilitado que las sofisticadas capacidades computacionales de estos modelos resulten accesibles para el gran público, incluso sin experiencia previa. No obstante, para que el modelo ofrezca respuestas adecuadas a las consultas de los usuarios, resulta necesario saber cómo comunicarse con él mediante la formulación de un *prompt* apropiado.

1.1. Qué es un *prompt*

El ***prompt***, entendido como **instrucción** o **entrada**, funciona como un puente de traducción entre la comunicación humana y las capacidades computacionales de los LLM (Fagbohun *et al.*, 2023). Se compone de instrucciones formuladas en lenguaje natural que actúan como intermediarias, al transformar las peticiones humanas en tareas susceptibles de ser ejecutadas por el software (Liu *et al.*, 2023b). Más allá de una instrucción puntual, los *prompts* configuran un marco contextual para la interacción, al transmitir la relevancia de la información y delimitar tanto el formato como el contenido esperado en la salida del modelo.

Aunque la interacción en lenguaje natural mediante *prompts* puede generar la percepción de resultar altamente accesible, diversos estudios han demostrado que los usuarios sin experiencia en inteligencia artificial presentan, en gran medida, dificultades para emplear un LLM de forma eficiente en la resolución de tareas (Zamfirescu-Pereira *et al.*, 2023). La mayoría de las personas no recurre a técnicas avanzadas de *prompting*, y los *prompts* utilizados suelen ser breves, simples y poco elaborados, incluso en contextos en los que podrían optimizarse con relativa facilidad (Desmond y Brachman, 2024; Zamfirescu-Pereira *et al.*, 2023).

No obstante, también se ha observado que cuando el propio sistema proporciona apoyo –por ejemplo, mediante la sugerencia de *prompts*, el uso de plantillas, la presentación de ejemplos o la visualización del proceso– los resultados mejoran y los usuarios perciben una colaboración más efectiva con la IA (Gutheil *et al.*, 2025; White *et al.*, 2023). Esto sugiere que el *prompting* no depende exclusivamente del usuario, sino también del diseño de la herramienta. Estas limitaciones han puesto de manifiesto la relevancia de la optimización estratégica de los *prompts* y han impulsado la necesidad de perfiles especializados en esta materia.

Un *prompt* está compuesto por varios componentes clave que funcionan conjuntamente para guiar a la IA. Aunque no todos los *prompts* contienen necesariamente todos los elementos que se muestran a continuación, conocerlos y entender la función de cada uno de ellos es fundamental para redactarlos de forma eficaz (Kuka, 2025):

- **Directiva:** la directiva es la instrucción principal del *prompt*. Recoge la tarea que se debe realizar y debe ser lo más clara y concisa posible para evitar respuestas genéricas o irrelevantes. La directiva puede incluir ejemplos para guiar a la IA.

- **Rol (Persona):** el rol indica a la IA que actué como un determinado experto, de acuerdo con un estilo determinado o tono.
- **Formato de salida:** el formato de salida permite especificar el formato en que se desea que el modelo presente la respuesta (tabla, texto en prosa, en un lenguaje de programación específico y con unas estructuras determinadas…).
- **Información adicional:** en el *prompt* es posible incluir información adicional de contexto o antecedentes que la IA puede necesitar para generar respuestas más precisas, así como para evitar generalizaciones o alucinaciones. Esto incluye aportar documentos, datos o ejemplos extensos.

Aunque no existe un mejor orden para todos los *prompts*, la recomendación más habitual es iniciarlos con los ejemplos o información adicional (por ejemplo, ficheros adjuntos), seguir con el rol, continuar con la directiva y finalizar con el formato de salida esperado. En este sentido, cuando en una consulta se aporta primero el contexto y luego la pregunta, el modelo procesa la pregunta habiendo visto ya el contexto, mientras que, si se comienza con la pregunta para, posteriormente, aportar el contexto, podría no disponer de esa información en el mismo marco contextual durante el procesamiento inicial (Leviathan *et al.*, 2025).

1.2. Qué es la ingeniería de *prompts*

La **ingeniería de *prompts*** se define como el proceso estratégico de diseño de entradas o instrucciones específicas para cada tarea, orientadas a guiar a los LLM en la generación de respuestas pertinentes y alineadas con los objetivos planteados (Fagbohun *et al.*, 2023; Sahoo *et al.*, 2025).

Los ingenieros de *prompts* explotan las capacidades predictivas y los amplios conjuntos de datos de entrenamiento de los modelos de IA, combinándolos con los matices propios de la comunicación humana para influir de manera estratégica en el comportamiento del modelo sin recurrir a un entrenamiento específico para cada tarea (Brown *et al.*, 2020; Petroni *et al.*, 2019; Radford *et al.*, 2019; Schick y Schütze, 2021). Una ingeniería de *prompts* eficaz aplica de forma táctica diversas buenas prácticas de diseño, seleccionadas según el contexto, con el fin de maximizar el rendimiento de los LLM y hacerlos más precisos y relevantes en tareas concretas.

Mientras que un *prompt* cuidadosamente diseñado puede orientar a estos modelos hacia la generación de respuestas más precisas, relevantes y adecuadas al contexto, los *prompts* deficientes pueden conducir a salidas ambiguas, irrelevantes o incluso incorrectas (Brown *et al.*, 2020; Ouyang *et al.*, 2022). En consecuencia, la efectividad de los LLM en aplicaciones prácticas depende en gran medida de la calidad de la ingeniería de *prompts* y del grado de experiencia de quienes los desarrollan.

El rápido y fragmentado crecimiento de las técnicas de *prompting* dificulta que los profesionales identifiquen qué enfoque resulta más adecuado en cada situación (Fagbohun *et al.*, 2023), lo que ha contribuido a que la ingeniería de *prompts* se consolide como una técnica clave para potenciar las capacidades tanto de los LLM como de los

modelos visión-lenguaje (*vision-language models*, VLM)[3] (Bahng *et al.*, 2022; Sahoo *et al.*, 2025).

Los estudios que han evaluado estas técnicas en contextos de uso reales –como la programación, la escritura, el análisis de requisitos o el aprendizaje– coinciden en señalar que no existe un *prompt* universalmente óptimo y que su efectividad depende de factores como la tarea concreta, el modelo empleado y el dominio de aplicación (Chen *et al.*, 2024; Garcia *et al.*, 2025). En general, los *prompts* bien estructurados, que incorporan ejemplos claros y proporcionan indicaciones explícitas sobre lo que la IA puede o debe hacer, tienden a ofrecer mejores resultados que formulaciones genéricas del tipo "actúa como un experto" o instrucciones vagas y poco organizadas (Wang *et al.*, 2024; DiCuffa *et al.*, 2025; Garcia *et al.*, 2025). En consecuencia, la forma y la estructura del *prompt* resultan más determinantes que el tono o la asignación de un rol.

Este informe recoge buenas prácticas en materia de *prompting* y diversas técnicas específicas documentadas en la literatura (Fagbohun *et al.*, 2023; Sahoo *et al.*, 2025), para finalizar con un conjunto de ejemplos aplicables a diferentes ámbitos relacionados con el área de conocimiento de la información y la documentación.

[3] Modelos que integran información visual y textual para comprender o generar salidas a partir de ambas modalidades (Rahman, 2026).

2. Buenas prácticas en materia de *prompting*

2.1. Buenas prácticas generales orientadas a la redacción y estructuración de los *prompts*

En materia de **buenas prácticas de *prompting*** encontramos un conjunto de principios operativos orientados a mejorar la calidad, la fiabilidad y la controlabilidad de las respuestas generadas por modelos de lenguaje (Fagbohun *et al.*, 2024).

En primer lugar, la literatura subraya la importancia de formular instrucciones claras. Esto implica incluir detalles relevantes en la consulta, definir explícitamente la persona o el tono deseado, separar las distintas partes del encargo mediante delimitadores y especificar el formato esperado de la salida. La claridad inicial del *prompt* actúa como un marco que reduce la ambigüedad interpretativa del modelo.

En segundo lugar, se destaca la necesidad de proporcionar un contexto relevante. El uso de textos de referencia, la aportación de información adicional, la descripción explícita del problema y la inclusión de ejemplos auxiliares permiten situar la tarea y acotar el espacio de respuesta, favoreciendo resultados más ajustados al objetivo planteado.

Rol:
Actúa como un especialista en análisis de legibilidad de textos en inglés.
Contexto:
El texto adjunto forma parte de una guía de uso en línea del catálogo de una biblioteca universitaria y está dirigido principalmente a estudiantes.
Tarea:
Calcula el índice de legibilidad SMOG del texto en inglés e interpreta brevemente el resultado en términos del nivel lector aproximado necesario para comprenderlo.
Requisitos:

- No reescribas, corrijas ni resumas el texto.
- Aplica la fórmula estándar de SMOG: 1,0430 × √(número de palabras polisilábicas × 30 / número de frases) + 3,1291.
- Considera como palabras polisilábicas las palabras de tres o más sílabas.
- Indica el número de frases analizadas y el número de palabras polisilábicas utilizadas en el cálculo.
- Si el texto tiene menos de 30 frases, señala expresamente que el resultado es una estimación menos fiable.
- No infieras datos no observables ni simules un cálculo exacto si no puedes contar de manera fiable frases o

palabras polisilábicas; en ese caso, indícalo como limitación.
- Utiliza un tono descriptivo y no prescriptivo.

Formato de salida:
Un único párrafo en prosa que incluya el valor del índice, los datos básicos empleados en el cálculo y una breve interpretación del resultado.

En esta misma línea, trabajos recientes (Leviathan et al., 2025) sugieren que, en determinadas tareas y, especialmente cuando no se solicita razonamiento paso a paso, la repetición íntegra del *prompt* puede contribuir a mejorar la respuesta del modelo. Esta estrategia parece resultar útil porque refuerza la disponibilidad del contexto dentro de la propia entrada y facilita que el modelo reutilice con mayor eficacia la información relevante, sobre todo en consultas donde el orden de los elementos puede condicionar la interpretación. Además, su interés práctico radica en que no modifica el formato de salida y, en términos generales, no comporta un aumento apreciable de la longitud de la respuesta, por lo que tampoco incrementa de forma significativa el coste asociado a la generación de *tokens*[4] de salida. De este modo, puede entenderse como un ajuste simple de redacción y estructuración del *prompt* más que como una técnica compleja de razonamiento.

Un tercer principio consiste en dividir las tareas complejas. Para ello, se recomienda clasificar la intención de la consulta, resumir o filtrar diálogos extensos, segmentar documentos largos en partes manejables y proporcionar pasos explícitos que el modelo pueda seguir. Esta descomposición facilita el tratamiento de problemas complejos mediante operaciones más simples y controlables.

Asimismo, se señala la conveniencia de dar tiempo al modelo para "pensar". En la práctica, esto se traduce en requerir explicaciones de las respuestas, utilizar monólogos internos o consultas intermedias, solicitar la autoevaluación del resultado y plantear preguntas de seguimiento. Estas estrategias fomentan respuestas más elaboradas y reflexivas.

Rol:
Actúa como asistente técnico especializado en tratamiento de datos tabulares, con conocimientos en normalización de datos, limpieza de registros y cálculo básico en hojas de cálculo y ficheros CSV.
Contexto:
Estoy trabajando con un conjunto de datos para un análisis académico y necesito preparar un fichero CSV a partir de una tabla con registros heterogéneos. La tarea consiste en estandarizar el contenido, detectar inconsistencias formales y

[4] Un *token* es una unidad mínima de texto en la que un modelo de lenguaje divide la entrada para poder procesarla, y puede corresponder a una palabra completa, a una parte de una palabra, a un signo de puntuación o a otros elementos del texto.

realizar cálculos simples que después serán revisados por una persona.

Tarea general:

Procesa la siguiente tabla de datos y prepara una salida en formato CSV limpia y coherente.

Texto a analizar:

[Aquí se facilitaría la tabla o los registros a la IA]

Realiza la tarea siguiendo estrictamente estos pasos:

1. Identifica la estructura de los datos y determina qué columnas contiene la tabla, explicando brevemente la función de cada una si puede inferirse del contenido.
2. Limpia y normaliza los registros, corrigiendo únicamente aspectos formales como espacios sobrantes, mayúsculas y minúsculas inconsistentes, formatos de fecha, separadores decimales, valores vacíos o duplicados exactos.
3. Genera el contenido en formato CSV, respetando una estructura uniforme de columnas y un criterio consistente de codificación de valores.
4. Realiza los cálculos solicitados a partir de los datos ya normalizados, por ejemplo, recuentos, sumas, medias, porcentajes o subtotales, e indica claramente sobre qué campos se han aplicado.
5. Autoevalúa el resultado, señalando qué transformaciones han sido puramente mecánicas y qué casos dudosos, ambiguos o incompletos deberían revisarse manualmente antes de dar el fichero por definitivo.

Requisitos adicionales:

- No inventes datos ausentes ni completes información que no aparezca en los registros originales.
- Si detectas ambigüedades, consérvalas o señálalas explícitamente en lugar de resolverlas de forma arbitraria.
- Utiliza un tono técnico, preciso y neutral.
- Distingue claramente entre limpieza formal de datos e interpretaciones que requieran supervisión humana.

Formato de salida:

- Cinco apartados numerados, uno por cada paso del proceso.
- Un bloque titulado “CSV generado”, que incluya exclusivamente el fichero CSV final.
- Un bloque titulado “Cálculos realizados”, separado del anterior, con los recuentos, sumas, medias, porcentajes o métricas obtenidas.
- Un bloque titulado “Casos que requieren revisión humana”, con ambigüedades, datos incompletos o decisiones no resueltas automáticamente.

Otro eje relevante es el uso de herramientas externas. Se contempla la posibilidad de dar acceso a ficheros externos, aprovechar capacidades de navegación web, solicitar la ejecución de código mediante alguna API[5] o habilitar el uso de complementos relevantes. Estas prácticas amplían las capacidades del modelo más allá del texto proporcionado en el *prompt*.

Finalmente, se recomienda probar los cambios de manera sistemática. Ajustar los *prompts* de forma incremental, evaluar los resultados intermedios, comenzar con consultas simplificadas y formular preguntas relacionadas permite refinar progresivamente la interacción y comprender mejor el impacto de cada modificación.

Por su parte, Hewing y Leinhos (2024) identifican técnicas y enfoques adicionales que amplían el marco habitual del *prompting* y lo aproximan a una metodología más sistemática y reutilizable.

En primer lugar, introducen explícitamente el diseño de Personas y audiencias como elementos diferenciados. No se trata solo de asignar un rol al modelo, sino de definir con detalle a quién va dirigido el resultado, incorporando características, expectativas y el nivel de conocimiento del público objetivo. Esta distinción entre Persona del modelo y audiencia del contenido añade una capa de precisión comunicativa que no siempre está presente en guías básicas de *prompting*.

En segundo lugar, se refuerza la formulación de la tarea mediante la definición explícita de la intención y el objetivo, enfatizando el uso de verbos de acción y la delimitación clara del propósito del encargo. Este enfoque conecta el *prompting* con prácticas propias del diseño de tareas y de la redacción técnica orientada a objetivos.

Otro aporte relevante es la separación entre contexto y referencias. Mientras el contexto recoge información situacional y de fondo, las referencias se conciben como fuentes concretas, datos esenciales o documentos específicos que deben ser utilizados o citados. Esta diferenciación es especialmente pertinente en entornos académicos y profesionales donde la trazabilidad de la información es crítica.

También es importante explicitar la extensión, estructura y formato de la salida, incluyendo la solicitud de citas textuales o referencias a fuentes.

En cuanto al estilo, se introduce la definición del tono como un elemento independiente, vinculado a atributos como calidad, lujo, cercanía o alineación con una marca o estilo de escritura determinado.

Wang *et al.* (2024) plantean estrategias de *prompting* metacognitivo, orientadas a guiar no solo la producción de respuestas, sino también los procesos de razonamiento que el propio modelo despliega para alcanzarlas. En este enfoque, el *prompt* no se limita a formular una instrucción o tarea, sino que estructura la interacción en fases secuenciales de reflexión y control cognitivo, lo que contribuye a mejorar la coherencia, la explicabilidad y la fiabilidad de los resultados.

En concreto, proponen una secuencia de cinco etapas que pueden integrarse de forma explícita en el diseño del *prompt*. La primera corresponde a la clarificación de la

[5] Interfaz de programación de aplicaciones. Es un punto de acceso o conjunto de funciones con sintaxis definida que permite a un programa utilizar servicios o capacidades de otro sistema.

comprensión, en la que se solicita al modelo que explicite su interpretación inicial de la tarea o de las preguntas planteadas. Esta fase cumple una función análoga a la verificación de requisitos en el diseño de sistemas, ya que permite detectar ambigüedades conceptuales o malentendidos antes de avanzar hacia el razonamiento propiamente dicho. La segunda etapa consiste en un juicio preliminar, donde el modelo formula una primera evaluación basada en similitudes semánticas, contexto o contenido general. Se trata de una estimación inicial, deliberadamente provisional, que actúa como hipótesis de trabajo y que prepara el terreno para análisis más profundos. Este paso resulta especialmente útil en tareas de clasificación, comparación o detección de equivalencias conceptuales, ya que separa la intuición inicial del análisis crítico posterior. A continuación, el análisis crítico o evaluación reflexiva introduce una revisión explícita del juicio preliminar. En esta fase se invita al modelo a reconsiderar su evaluación inicial, contrastarla con matices relevantes, excepciones o criterios adicionales, y, si es necesario, reformular su posición. Este mecanismo de autorevisión es clave para reducir errores derivados de respuestas superficiales y se alinea con las recomendaciones de "dar tiempo al modelo para pensar", ya que fuerza un razonamiento más deliberado y estructurado. La cuarta etapa corresponde a la confirmación de la decisión, en la que el modelo debe emitir un juicio final explícito y justificarlo de manera razonada. Esta fase consolida el proceso argumentativo y permite obtener respuestas más transparentes, al hacer explícitos los criterios empleados y la lógica que sustenta la conclusión alcanzada. Finalmente, se incorpora una evaluación de la confianza, solicitando al modelo que estime el grado de seguridad de su respuesta, generalmente en términos porcentuales, y que explique las razones de dicha valoración. Aunque esta autoevaluación no equivale a una medida objetiva de fiabilidad, sí que aporta una señal adicional sobre la estabilidad del razonamiento y la claridad de los criterios aplicados, lo que puede resultar útil en contextos académicos, analíticos o de apoyo a la toma de decisiones.

Integradas en el marco general de buenas prácticas, estas estrategias de *prompting* metacognitivo refuerzan los principios previamente descritos. La claridad de instrucciones se amplía hacia la claridad del proceso; la descomposición de tareas incorpora fases explícitas de reflexión y revisión; y la evaluación sistemática de cambios se ve enriquecida por la posibilidad de analizar no solo la respuesta final, sino también las etapas intermedias del razonamiento. De este modo, el *prompting* deja de ser una técnica puramente instrumental para convertirse en un dispositivo metodológico que estructura, documenta y controla el proceso cognitivo del modelo de lenguaje.

Analiza la siguiente situación en una biblioteca pública:

La biblioteca ha decidido implantar un sistema automatizado que recomienda lecturas a los usuarios a partir de su historial de préstamos. El sistema almacena datos de uso durante cinco años y no ofrece al usuario la posibilidad de desactivar la personalización.

En primer lugar, explica cómo interpretas la situación y el problema ético planteado.

Interpretación de la situación y del problema ético

La situación describe la implantación, en una biblioteca pública, de un sistema automatizado de recomendación de lecturas basado en el historial de préstamos de los usuarios. Este sistema presenta tres características clave desde el punto de vista ético:

1. **Tratamiento intensivo de datos personales**, ya que el historial de préstamos puede revelar intereses culturales, ideológicos, religiosos, políticos o de salud, incluso aunque no se trate explícitamente de categorías especiales de datos.
2. **Conservación prolongada de la información** (cinco años), lo que incrementa los riesgos asociados al uso indebido, accesos no autorizados o reutilizaciones no previstas.
3. **Ausencia de control por parte del usuario**, dado que no se ofrece la posibilidad de desactivar la personalización ni de optar por un uso no profilado del servicio.

El problema ético central radica en la **tensión entre la mejora del servicio** —mediante recomendaciones personalizadas que pueden aumentar la satisfacción y el uso de la biblioteca— y el **respeto a los derechos fundamentales de los usuarios**, en particular la privacidad, la autonomía informacional y la libertad intelectual.

Desde una perspectiva bibliotecaria, el caso es especialmente sensible porque las bibliotecas públicas tienen una **tradición ética fuertemente vinculada a la confidencialidad de las lecturas**, al acceso libre y no vigilado a la información y a la no discriminación. Un sistema que perfila a los usuarios sin posibilidad de exclusión introduce un elemento de **vigilancia estructural**, aunque su finalidad sea aparentemente benigna.

En consecuencia, el dilema ético no se limita a una cuestión técnica o legal, sino que afecta al **rol social de la biblioteca**: si debe priorizar la eficiencia y la personalización del servicio o salvaguardar, incluso a costa de esa eficiencia, principios como la privacidad, el consentimiento informado y el derecho a explorar información sin ser observado o categorizado.

Formula un juicio preliminar sobre la adecuación ética de la práctica.

Juicio preliminar sobre la adecuación ética

De manera preliminar, la práctica descrita puede considerarse **éticamente problemática y difícilmente justificable** en el contexto de una biblioteca pública.

Aunque la recomendación automatizada de lecturas persigue un objetivo legítimo —mejorar el servicio y facilitar el descubrimiento de contenidos—, la forma concreta en que se implanta el sistema vulnera principios éticos básicos propios tanto de la ética profesional bibliotecaria como de la ética de la información en general.

En particular:

- **Se debilita la autonomía del usuario**, al no ofrecerle la posibilidad de decidir si desea o no ser objeto de personalización. La ausencia de una opción de exclusión elimina el consentimiento significativo y convierte la personalización en una imposición.
- **Se compromete la privacidad intelectual**, ya que el seguimiento sistemático y prolongado de las lecturas crea perfiles que pueden condicionar la relación del usuario con la institución y generar efectos inhibidores en el acceso a ciertos contenidos.
- **Se introduce un riesgo de normalización de la vigilancia**, incompatible con el papel histórico de la biblioteca como espacio seguro para la exploración libre de ideas.
- **La proporcionalidad es cuestionable**, dado que no se justifica éticamente la conservación de datos durante cinco años cuando podrían explorarse alternativas menos intrusivas (anonimización temprana, recomendaciones no personalizadas o basadas en datos agregados).

Por todo ello, aun reconociendo la buena intención del sistema y su potencial utilidad, el diseño actual no parece respetar el equilibrio ético adecuado entre beneficio del servicio y protección de los derechos de los usuarios. Un juicio preliminar razonable sería que la práctica **requiere modificaciones sustanciales** —especialmente en términos de control por parte del usuario y minimización de datos— para poder considerarse éticamente aceptable.

Reevalúa críticamente ese juicio considerando principios profesionales relevantes.

Reevaluación crítica del juicio a la luz de principios profesionales

Al reconsiderar el juicio preliminar desde los **principios profesionales que rigen la práctica bibliotecaria**, es posible matizar y reforzar la evaluación ética inicial, incorporando criterios normativos propios de la profesión y no únicamente argumentos generales sobre privacidad o tecnología.

Entre los principios más relevantes destacan:

1. **Confidencialidad de los usos de la biblioteca**
   Los códigos deontológicos bibliotecarios establecen que la información relativa a qué leen, consultan o toman en préstamo los usuarios debe protegerse de forma estricta. El registro sistemático del historial de préstamos durante cinco años, con fines de perfilado, entra en tensión directa con este principio. Aunque el acceso a los datos esté técnicamente restringido, el mero hecho de conservarlos y explotarlos algorítmicamente supone una erosión de la confidencialidad tradicionalmente defendida por la profesión.
2. **Libertad intelectual y ausencia de vigilancia**
   Las bibliotecas se conciben como espacios que garantizan el acceso libre a la información sin temor a ser observado o juzgado. Un sistema de recomendación obligatorio, basado en el comportamiento pasado, puede generar un efecto de autocensura: los usuarios pueden evitar ciertos préstamos por la conciencia de estar siendo registrados y clasificados. Desde este principio, la práctica no solo afecta a la privacidad, sino también al ejercicio efectivo de la libertad intelectual.
3. **Equidad y no discriminación**
   Los sistemas automatizados de recomendación tienden a reforzar patrones previos de consumo, limitando la diversidad y el descubrimiento accidental. En un servicio público, esto puede entrar en conflicto con el mandato profesional de promover el acceso equitativo a colecciones amplias y plurales. El diseño del sistema, al no permitir desactivación, impone una lógica algorítmica única a todos los usuarios, sin atender a diferentes expectativas o necesidades.
4. **Responsabilidad profesional y transparencia**
   La adopción de tecnologías no exime a la institución de su responsabilidad ética. Un principio profesional clave es la capacidad de explicar y justificar las prácticas ante la comunidad a la que se sirve. La falta de opciones de control por parte del usuario dificulta esta rendición de cuentas y debilita la relación de confianza entre biblioteca y ciudadanía.

A la luz de estos principios, el juicio preliminar no solo se mantiene, sino que se **refuerza**: la práctica, tal como está planteada, no se alinea adecuadamente con los valores profesionales de la biblioteconomía y la documentación. Incluso si se demostrara su eficacia técnica, seguiría siendo éticamente inadecuada mientras no incorpore mecanismos de respeto activo a la confidencialidad, la libertad intelectual y la autonomía del usuario.

La reevaluación, por tanto, conduce a una conclusión más sólida: el problema no es la existencia de recomendaciones automatizadas en sí, sino su **implantación acrítica**, que subordina principios profesionales fundamentales a criterios de eficiencia tecnológica.

Emite una valoración final razonada.

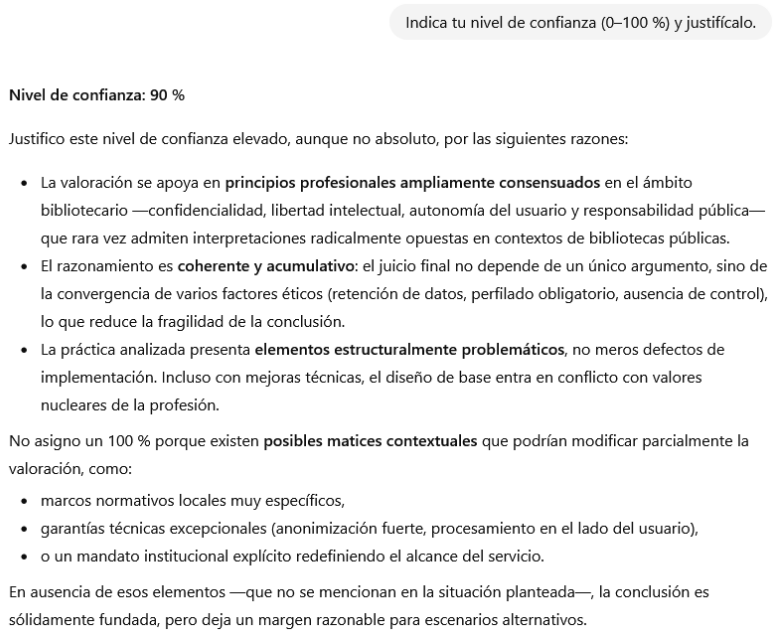
Valoración final razonada

La práctica, tal como se describe, es **éticamente inadecuada para una biblioteca pública**. No por incorporar un sistema de recomendación en sí, sino por hacerlo mediante un modelo de **perfilado obligatorio**, con **retención prolongada** y sin **capacidad de decisión del usuario**.

En una biblioteca pública, la legitimidad ética del servicio se apoya en una relación de confianza con la ciudadanía y en principios profesionales como la **confidencialidad de los usos**, la **libertad intelectual**, la **autonomía informacional** y la **equidad**. En este caso, el sistema introduce una lógica de vigilancia normalizada: convierte un rastro de lectura altamente sensible en un activo permanente (cinco años) y lo utiliza para inferir preferencias sin posibilidad de exclusión. Esto incrementa riesgos de seguridad y de reutilización indebida, pero sobre todo crea un **efecto inhibidor** incompatible con el papel de la biblioteca como espacio de exploración libre.

Además, la ausencia de desactivación no es un detalle operativo: es el punto que desbalancea toda la justificación ética. La personalización puede ser defendible cuando es **proporcionada**, **voluntaria**, **transparente** y **reversible**. Aquí no lo es. En términos profesionales, la biblioteca no está simplemente "mejorando la experiencia"; está **redefiniendo la relación usuario–institución** hacia un modelo de seguimiento persistente que no respeta expectativas razonables de privacidad.

Conclusión: la práctica debe considerarse **no aceptable en su diseño actual**. Para aproximarse a una posición ética defendible, sería necesario, como mínimo, incorporar una opción clara de **opt-out**, aplicar **minimización y reducción de retención** (o anonimización temprana), y asegurar **transparencia y control** real por parte del usuario, además de salvaguardas de equidad y auditoría del sistema. Sin esos cambios, el coste ético supera el beneficio esperado del servicio.



2.2. Sintaxis

En el uso de estas herramientas conviene seguir algunas convenciones de sintaxis para estructurar mejor los *prompts*.

En líneas generales, es preferible **situar las instrucciones al inicio** y **separar claramente instrucciones** y **contexto** mediante delimitadores con el fin de reducir ambigüedades y mejorar la fiabilidad de la respuesta. Open AI (2025) recomienda, por ejemplo, usar los caracteres ### o """ para introducir el contexto. Por ejemplo:

> *Extrae del texto: título, autor, fecha y tema principal. Devuelve un JSON válido.*
> *Texto: """*
> {aquí el texto}
> *"""*

También Open AI (MacCallum y Lee, 2025) en sus directrices para desarrolladores recomienda usar **marcado ligero en Markdown**[6] para las secciones y subsecciones principales, así como para jerarquías más profundas si es necesario, listas, etc. También usar comillas invertidas simples (*backticks*) en línea o bloques delimitados por *backticks* para envolver el código con precisión, y listas estándar numeradas o con viñetas cuando sea necesario.

> *# Análisis de logs de servidor*
> *## Objetivo*
> *Identifica las causas más probables de errores **500** y propón acciones correctivas.*

[6] Markdown es un lenguaje de marcado ligero para dar estructura básica al texto. Los *backticks* son comillas invertidas usadas en Markdown para delimitar código en línea o bloques de código

Entrada
Contexto
- Entorno: 'Ubuntu 22.04'
- Servidor web: 'Nginx'
- App: 'PHP-FPM'
- Ventana temporal: 2026-02-01 a 2026-02-15
Logs
```
{aquí los logs}
```

Al utilizar *prompts* complejos que incorporan varios componentes (instrucciones, contexto, ejemplos...), el uso de lenguajes de marcas estructurados ayuda a los LLM a interpretarlos con mayor precisión. Con ellos es posible desarrollar *prompts* más claros, estructurados, precisos, flexibles y reutilizables (resulta más fácil añadir, eliminar o modificar secciones fácilmente) o incluso que tanto el usuario como el modelo puedan referirse más fácilmente a secciones concretas del *prompt* bien identificadas (Claude, 2026). En el caso de utilizar lenguajes de marcas como XML o JSON (MacCallum y Lee, 2025), es importante ser consistentes durante toda la interacción con el LLM.

```
<prompt>
 <instructions>
  Resume el contenido de <context> en 5–7 viñetas.
  - No añadas ni asumas nada que no aparezca en el texto.
  - Mantén nombres propios y fechas exactamente como aparecen.
 </instructions>
 <formatting>
  Devuelve la respuesta así:
  <output>
   <bullet_points>
    - ...
   </bullet_points>
  </output>
 </formatting>

 <context>
  <document title="Informe de actividad" date="2026-02-10">
   {aquí el texto a resumir}
  </document>
 </context>

 <examples>
  <example>
   <output>
    <bullet_points>
     - El proyecto comenzó en enero de 2025.
     - Participaron Ana y Luis.
     - El objetivo fue digitalizar 300 incunables.
    </bullet_points>
   </output>
  </example>
 </examples>
</prompt>
```

Si no se desea utilizar una sintaxis tan verbosa, como mínimo se recomienda utilizar prefijos de entrada / salida para marcar semánticamente partes de contenido (Gemini, 2025).

> *Instrucción:* {aquí la instrucción}
> *Texto:* ` ` ` {aquí el texto que debe procesar} ` ` `
> *Formato de salida:* {aquí el formato de salida deseado}

Al trabajar con ficheros conviene tanto trabajar con formatos estructurados (mejor un CSV que un PDF), como explicar en el *prompt* cómo se encuentran organizados los datos en esos ficheros.

2.3. Seguridad

En el diseño de *prompts* conviene partir de un principio sencillo: el *prompt* no debe convertirse en un canal para manejar **secretos**. Esto implica evitar la exposición indirecta por "comodidad" (pegarlas en el contexto, en ejemplos o *prompt*) de nombres de usuario, contraseñas, claves API, entre otros. El objetivo es reducir el **riesgo de exfiltración** –por filtrado en la propia respuesta, por registro en logs, o por propagación a herramientas externas– y asumir que, si un secreto entra en el contexto del modelo, deja de estar bajo nuestro control (OWASP, 2025). Relacionado con lo anterior, hay que tratar los *prompts* como **semipúblicos**. En la práctica, un atacante puede intentar forzar su revelado de forma directa (solicitándolo) o indirecta (mediante inyección de instrucciones, contenido recuperado en RAG[7] o manipulación de herramientas), y además puede inferir parte de la lógica de control observando respuestas.

Finalmente, un área especialmente sensible es la salida del modelo cuando se convierte en entrada de otros sistemas. Esta situación se da, por ejemplo, cuando se solicita código SQL, comandos, *scripts*, reglas de cortafuegos, consultas a APIs u otros. Una buena práctica es especificar formatos estructurados y requisitos de seguridad ("no generes comandos destructivos", "no incluyas *payloads*", "documenta supuestos"), pero, sobre todo, asumir que el texto generado no se debe ejecutar ni desplegar sin validación previa (OWASP, 2025). Esto exige **controles y revisión humana** en acciones de alto impacto y pruebas en entornos aislados. La idea es evitar "copiar-pegar y ejecutar" y optar por un flujo de trabajo en el que el modelo se limita a producir borradores.

[7] Técnica que combina un modelo generativo con recuperación de información externa, incorporando al *prompt* fragmentos recuperados de una base documental para mejorar la actualización y la precisión factual de la respuesta.

2.4. Privacidad y datos personales

Estrechamente relacionado con el apartado anterior, otro aspecto importante es no introducir **datos personales** identificables, credenciales, códigos, claves API, conexiones a bases de datos o cualquier otro tipo de información sensible. Para trabajar con seguridad es imprescindible anonimizar o seudonimizar (sustituir datos reales por alias como [Persona A] o [Empresa B]), eliminar o generalizar campos innecesarios (fechas exactas, ubicaciones concretas, números de identificación reales…) y compartir únicamente el mínimo fragmento de texto o datos requerido para obtener una respuesta útil. En esa misma línea, conviene evitar adjuntar documentos completos si no es estrictamente necesario. Es preferible pegar extractos acotados, recortar tablas a las columnas relevantes, resumir el contexto con variables o plantillas, y revisar antes de enviar que no queden "rastros" en metadatos, encabezados, firmas, capturas o rutas de archivo. Estas medidas reducen la exposición, facilitan el cumplimiento normativo y minimizan riesgos de filtración o reutilización indebida de información. Finalmente, cuando se trata de información extremadamente sensible se debe priorizar el uso de modelos de código abierto e instalados en local, frente a servicios disponibles en abierto en la nube.

Al trabajar específicamente con imágenes, conviene evitar rostros, direcciones, documentos fotografiados, credenciales o códigos identificables. También resulta imprescindible eliminar todos los metadatos incrustados (EXIF, XMP, IPTC…)[8] en los ficheros antes de cargarlos, entre ellos puede haber información de localización, fechas, modelos de dispositivos, identificadores, notas, entre otros. Para ello se pueden utilizar herramientas como ExifTool.[9]

Más allá de los metadatos, es importante revisar otros datos "invisibles" o no perceptibles a primera vista como reflejos en cristales, miniaturas incrustadas en el fichero (por ejemplo, en formatos RAW), capas en formatos como DNG o TIF. Esto incluye también los nombres de los ficheros, los cuales en algunos casos pueden ser muy informativos.

Por supuesto, no deben integrarse datos relacionados con menores u otros colectivos vulnerables.

[8] EXIF es un conjunto de metadatos técnicos incrustados en imágenes y otros ficheros; XMP es una tecnología estandarizada para incrustar metadatos en ficheros; IPTC es un estándar ampliamente usado para metadatos descriptivos, administrativos y de derechos en imágenes.
[9] En esta guía se muestra cómo realizarlo: Alcaraz Martínez, Rubén (2026). *Guía de uso de ExifTool*. https://hdl.handle.net/2445/226841

2.5. Cuestiones éticas

Las consideraciones éticas en el diseño de *prompts* son fundamentales (Tokayev, 2023), ya que, pese a las notables capacidades de los LLM, estos presentan desafíos éticos relevantes que deben abordarse para garantizar un uso responsable y seguro. Entre ellos destaca la capacidad de generar salidas sesgadas (O'Neil, 2017), derivadas tanto de los datos de entrenamiento como del propio diseño de los *prompts*. Estos sesgos pueden manifestarse en estereotipos, prejuicios o representaciones injustas de determinados grupos o ideas (Tokayev, 2023). Los sesgos ocupan un lugar central entre las cuestiones éticas. No obstante, por su importancia y dado que su mitigación exige técnicas específicas de formulación y revisión, este aspecto se aborda de forma específica en el apartado siguiente.

Con todo, el *prompting* ético no se limita a la reducción de sesgos, sino que implica la elaboración de *prompts* alineados con normas y valores sociales, orientados a promover la equidad y a fomentar respuestas constructivas (Shaikh et al., 2022). Con ello se busca asegurar que las salidas respeten principios éticos y contribuyan positivamente al bienestar colectivo, lo que exige evaluar cuidadosamente las posibles consecuencias de los *prompts* y guiar a los LLM hacia la generación de contenidos responsables y socialmente aceptables mediante la reformulación iterativa de las respuestas (Ma et al., 2023). En este marco, también resulta necesario considerar como riesgo la posible **reproducción no autorizada de contenidos preexistentes**. Investigaciones recientes (Liu et al., 2026) han mostrado que, bajo determinadas condiciones, los modelos pueden llegar a reactivar y reproducir fragmentos literales o muy próximos a obras protegidas por derechos de autor, incluso a partir de instrucciones semánticas que no contienen el texto original. Este hallazgo cuestiona la idea de que los modelos únicamente "aprenden patrones" de forma abstracta y obliga a incorporar al análisis ético del *prompting* la posibilidad de inducir, aunque sea de manera no intencional, respuestas que repliquen expresiones protegidas o excesivamente dependientes de materiales ajenos.

Un primer aspecto que resulta necesario considerar antes de interactuar con un LLM es si contamos con el **consentimiento** y la **autorización** necesaria al utilizar contenido de terceros en los *prompts*. Esta precaución es especialmente relevante cuando se introducen materiales que no son de elaboración propia o que contienen información no destinada a su difusión o reutilización en este tipo de herramientas, como materiales docentes, trabajos de estudiantes, correos electrónicos, informes internos, manuscritos en evaluación, actas de reuniones o documentos profesionales compartidos en contextos de confianza. Estas prácticas pueden plantear problemas éticos –y, en algunos casos, legales– si no existe autorización expresa de las personas implicadas. Del mismo modo, introducir fragmentos de entrevistas, expedientes o evaluaciones sin una **anonimización** adecuada puede vulnerar compromisos de confidencialidad. Incluso cuando el contenido introducido no sea sensible, ciertos *prompts* pueden empujar al modelo a reconstruir o aproximarse en exceso a textos protegidos, especialmente si se le solicita continuar, expandir, reescribir "en el mismo estilo" o desarrollar pasajes a partir de resúmenes detallados. Por ello, antes de usar

este tipo de materiales conviene verificar la legitimidad de su uso, valorar si el tratamiento es proporcional a la finalidad perseguida y, cuando sea posible, optar por versiones anonimizadas, sintetizadas o con datos ficticios equivalentes. Del mismo modo, conviene formular las instrucciones de manera que promuevan la elaboración original, la síntesis y la transformación crítica, y no la reproducción de expresiones reconocibles o atribuibles a terceros.

Otro aspecto fundamental gira en torno a la necesaria **supervisión** y **validación humana** de las respuestas obtenidas. Los autores deben responder siempre por el resultado final, evitando delegar decisiones sensibles de forma automática en el sistema. Esta exigencia es especialmente importante cuando las respuestas del LLM pueden influir en decisiones profesionales, recomendaciones a terceros o comunicaciones con impacto reputacional, jurídico o social. Por ejemplo, emitir una recomendación profesional basada en un resumen no verificado, o redactar una respuesta institucional sobre un asunto delicado sin comprobar datos, tono y contexto, puede trasladar indebidamente al sistema una responsabilidad que corresponde a la persona. Además de posibles errores factuales (alucinaciones), los LLM pueden omitir matices relevantes, introducir formulaciones ambiguas o presentar con excesiva seguridad contenidos discutibles. Asimismo, pueden generar pasajes indebidamente próximos a fuentes preexistentes sin señalizarlo de forma clara, lo que incrementa el riesgo de reutilización acrítica de materiales ajenos. Por ello, su uso debe entenderse como el propio de una herramienta de soporte a la redacción, no como sustituto del juicio experto, lo que implica revisar críticamente las respuestas, contrastar la información cuando proceda, verificar la originalidad y adecuación del contenido generado y asumir explícitamente la responsabilidad sobre la versión final.

El **uso de la IA debe declararse**, especialmente cuando su intervención haya influido en la búsqueda de información, la elaboración de contenidos, la redacción, el análisis o la toma de decisiones, y con mayor motivo en contextos académicos, científicos, profesionales o institucionales donde la transparencia metodológica y la atribución de responsabilidades resultan esenciales. Esta exigencia de transparencia también resulta pertinente porque permite contextualizar cómo se han obtenido determinadas formulaciones, síntesis o propuestas textuales y advertir de los límites del proceso, incluidos los riesgos de sesgo, error o dependencia excesiva de materiales previos.

Resnik y Hosseini (2025) proponen una serie de escenarios en los que el uso de la IA debe declararse obligatoriamente, opcionalmente o en los que no es necesario, en el marco de investigaciones y publicaciones académicas (tabla 1).

Tabla 1. Criterios y ejemplos de usos de la IA que deben declararse obligatoriamente, de forma opcional o que no son necesarios declarar de acuerdo con Resnik y Hosseini (2025).

Categoría	**Criterio**	**Ejemplos**
Obligatoria	La declaración debe ser obligatoria solo cuando el uso de IA sea intencional y sustancial. El uso de IA es sustancial cuando 1) produce evidencia, análisis o discusión que sustenta o desarrolla las conclusiones/hallazgos de un estudio; o 2) afecta directamente al contenido de la investigación / publicación. La declaración del uso de IA debe ser obligatoria cuando cumpla al menos uno de estos criterios: (a) La herramienta de IA toma decisiones que afectan directamente a los resultados de la investigación; (b) La herramienta de IA genera o sintetiza contenido, datos o imágenes; o (c) La herramienta de IA analiza contenido, datos o imágenes.	– Para formular preguntas o hipótesis, diseñar y realizar experimentos. – Para redactar partes del artículo, resumir, parafrasear, revisar significativamente o sintetizar contenido textual. – Para traducir partes o la totalidad del artículo. – Para recopilar, analizar, interpretar o visualizar datos (cuantitativos o cualitativos). – Para extraer datos para la revisión de la literatura (sistemática o no) e identificar lagunas de conocimiento. – Para generar datos e imágenes sintéticos utilizados en la investigación.
Opcional	Los autores distinguen tres situaciones (obligatoria, opcional e innecesaria). En el caso de la categoría opcional, la adscripción se apoya en ejemplos y en consideraciones contextuales.	– Para editar texto existente en cuanto a gramática, ortografía u organización. – Para encontrar referencias o verificar la pertinencia de referencias encontradas por humanos. – Para encontrar y generar ejemplos para contenido existente. – Para hacer lluvia de ideas y ofrecer sugerencias para la organización de un artículo o el título de un artículo/sección. – Para validar u ofrecer retroalimentación sobre ideas, texto y código existentes
Innecesaria	La declaración es innecesaria cuando el uso de la IA no es sustancial.	– Para sugerir palabras o frases que mejoren la claridad / legibilidad de una oración existente. – Como parte de una operación más amplia en la que la IA no está generando ni sintetizando contenido ni tomando decisiones de investigación; por ejemplo, cuando la IA está integrada en otros sistemas/máquinas. – Como asistente digital, por ejemplo, para ayudar a organizar y mantener los activos digitales y los flujos de trabajo de un proyecto.

2.6. Control de sesgos

En continuidad con las cuestiones éticas expuestas en el apartado anterior, este apartado se centra la identificación y mitigación de sesgos en la formulación de *prompts* y en la revisión de las respuestas.

Es sabido que los LLM son sensibles a ciertos sesgos. Los sesgos algorítmicos consisten en que el modelo puede producir respuestas sistemáticamente inclinadas, injustas, estereotipadas o desiguales hacia ciertos grupos, ideas, lenguas, culturas o perspectivas (Comisión Europea, 2019). Los sesgos no se limitan a un desequilibrio demográfico o a la representatividad de los datos. El marco AI RMF 1.0 (NIST, 2023) distingue al menos tres grandes categorías de sesgo: sistémico, computacional / estadístico y humano-cognitivo, y subraya que pueden aparecer incluso sin una voluntad discriminatoria. Esta distinción es especialmente útil en el contexto de los LLM, ya que permite entender que los sesgos observables en las respuestas pueden derivar tanto del corpus y los procesos algorítmicos como de los marcos organizativos y de las propias interpretaciones humanas durante el diseño, uso y evaluación del sistema. Por ello, los diseñadores de *prompts* deben ser conscientes de estos riesgos y actuar de forma proactiva para mitigarlos, revisando y depurando las formulaciones con el fin de evitar la reproducción de estereotipos dañinos o contenido discriminatorio.

En líneas generales, los LLM son sensibles a sesgos en al menos dos sentidos: (1) pueden reproducir sesgos en sus respuestas porque han aprendido a partir de datos y decisiones humanas; y (2) pueden activar sesgos como resultado de un *prompt* tendencioso que influye en la respuesta. Por lo tanto, tanto el preentrenamiento, como el contexto de trabajo, la formulación de los *prompts* o, incluso los criterios de parametrización y ajuste de la herramienta (qué se considera una respuesta adecuada, etc.), pueden producir sesgos en un sentido determinado (Torres-Salinas, 2025).

Los **sesgos derivados de un entrenamiento específico** pueden, en parte, mitigarse mediante *prompts* que delimiten explícitamente el alcance de la consulta e incorporen diversidad geográfica, cultural, temporal y epistemológica. Así, en lugar de formular preguntas como "¿Quién inventó la medicina moderna?", podríamos aproximarnos mediante formulaciones tales como: "¿Cómo se desarrolló la medicina moderna a partir de aportaciones de diferentes tradiciones médicas y contextos históricos?", con el objetivo de evitar reproducir el posible desequilibrio en la representación de temas, culturas, tradiciones, etc., sobrerepresentadas durante el entrenamiento. Ahora bien, la reformulación de *prompts* para mitigar sesgos no debe llevar a una "corrección" acrítica de signo contrario. Es recomendable revisar las respuestas para comprobar que la búsqueda de diversidad y representación no produzca selecciones forzadas, desproporcionadas o poco justificadas en relación con la evidencia disponible, la relevancia histórica o el contexto de la consulta. En otras palabras, mitigar sesgos no consiste en sustituir un canon limitado por una lista artificial, sino en ampliar y contextualizar la respuesta con criterios explícitos y una representatividad razonada.

En el caso de los **sesgos introducidos a través de las instrucciones**, uno que puede darse de forma habitual es el sesgo de confirmación. Por ejemplo, preguntas como

¿Por qué el teletrabajo reduce la productividad? o ¿Por qué las redes sociales dañan la salud mental? Introducen afirmaciones implícitas que orientan la respuesta hacia una conclusión predeterminada y pueden reforzar un sesgo de confirmación, en lugar de favorecer un análisis equilibrado de factores, contextos y evidencias. En este sentido, formulaciones como "¿Qué efectos tiene el teletrabajo sobre la productividad según el tipo de tarea, sector y condiciones laborales?" o "¿Qué relación existe entre redes sociales y salud mental, y qué factores pueden generar efectos positivos o negativos?" permiten desplazar la consulta desde una premisa cerrada hacia un enfoque analítico más abierto, contextualizado y matizado, favoreciendo respuestas que consideren variables, condiciones y resultados diversos en lugar de confirmar una hipótesis previa.

Los ejemplos anteriores recogen ejemplos de sesgos culturales derivados del preentrenamiento o de confirmación en la instrucción escrita por el usuario. Otros posibles sesgos que conviene mitigar son:

- **Geográficos:** se produce cuando la pregunta o la respuesta privilegia implícitamente realidades, referencias o criterios de una región (a menudo occidentales), presentándolos como universales. Por ejemplo, "¿Cuál es el mejor modelo educativo?" frente "¿Compara modelos educativos de diferentes países o regiones, indicando fortalezas, limitaciones y contexto de aplicación?"
- **De generalización:** se produce cuando se atribuyen rasgos, conductas o carencias a un grupo amplio (por edad, país, generación, etc.) como si fuera homogéneo. Por ejemplo, "¿Por qué los jóvenes no leen?" o "¿Por qué las personas mayores no entienden las tecnologías?, en lugar de "¿Qué hábitos de lectura presentan distintos grupos de jóvenes y qué factores influyen en ellos?" o "¿Qué barreras y facilitadores influyen en la adopción tecnológica en cada grupo de edad?").
- **De lenguaje valorativo:** aparece cuando la formulación incorpora términos con carga emocional, moral o ideológica que orientan la respuesta hacia una interpretación previa. Por ejemplo, "¿Cuáles son las ideologías más peligrosas?" en lugar de "¿Qué riesgos y efectos históricos se han asociado a distintas ideologías en determinados contextos, y según qué criterios se evalúan?").
- **Sesgo temporal o presentista:** se produce cuando se juzgan prácticas, ideas o procesos del pasado con categorías o expectativas del presente, o cuando se presupone que lo más reciente es necesariamente superior. Por ejemplo, "Las metodologías tradicionales ya no sirven, ¿verdad?", en lugar de "¿Qué ventajas y limitaciones presentan metodologías tradicionales y contemporáneas según el tipo de aprendizaje?".
- **Sesgo binario o de falsa dicotomía:** aparece cuando la pregunta reduce un problema complejo a dos opciones excluyentes, ignorando alternativas intermedias, combinaciones o matices. Por ejemplo, "¿Es mejor la enseñanza presencial o la online?" en lugar de "¿Qué ventajas y limitaciones

tienen la enseñanza presencial, online e híbrida según objetivos, perfil del alumnado y contexto?".

- **Sesgo de anclaje:** aquí la primera premisa o dato del *prompt* fija un marco que condiciona la respuesta. Por ejemplo, "Partiendo de que el fracaso escolar se debe principalmente a la falta de esfuerzo…"
- **Sesgo de encuadre:** cuando en la formulación se introduce un marco semántico que orienta la interpretación. Por ejemplo, "¿Cómo evitar que la regulación ahogue la innovación?" en lugar de "¿Cómo pueden diseñarse marcos regulatorios que equilibren innovación, competencia, seguridad y derechos?"
- **Sesgo por omisión:** se produce cuando se dejan fuera perspectivas, grupos, periodos o contraejemplos relevantes. Por ejemplo, "Dame una lista de los grandes filósofos de la historia", que puede dejar fuera a ciertas tradiciones o a filósofas en el corpus de entrenamiento.

Finalmente, es importante tener en cuenta que un mismo *prompt* puede activar varios sesgos simultáneamente. En este sentido, resulta útil identificar cuál es el sesgo principal que estructura la pregunta y qué sesgos secundarios lo refuerzan, para poder reformularla de manera más precisa, contextualizada y equilibrada, pero teniendo en cuanta también que no se debe alterar innecesariamente la intención de la consulta.

2.7. Uso responsable y sostenible

En líneas generales el factor más ligado al **consumo energético** es la **longitud de la respuesta** y no tanto la longitud del *prompt* (Adamska et al., 2025). No obstante, elementos del *prompt* como el tipo de tarea, complejidad, apertura / cierre de la instrucción, entre otros, influyen de forma significativa en la extensión de la respuesta. En este sentido, algunas recomendaciones para producir *prompts* más "verdes" son (Adamska et al., 2025):

- Diseñar *prompts* que induzcan respuestas más cortas.
- No asumir que un *prompt* más corto será necesariamente más eficiente. Es decir, recortar *tokens* del *prompt* por sí mismo, no tiene un impacto significativo en el consumo energético.
- Formular *prompts* muy específicos y con instrucciones muy concretas, ya que reducen la necesidad de incurrir en varias interacciones con el LLM hasta que devuelva lo que se precisa.
- Utilizar proyectos y referirse en los *prompts* a datos, documentos o instrucciones facilitadas previamente al LLM.
- Solicitar salidas en formatos restringidos y concretos. Por ejemplo, especificando el lenguaje de programación, estructura del código esperado, bloques o apartados de la respuesta, entre otros.
- Evitar solicitar explicaciones detalladas si no son imprescindibles.
- Solicitar sólo aquellos fragmentos necesarios que deben modificarse, por ejemplo, en un código fuente, fórmula, etc.

3. Clasificación y ejemplificación de las técnicas de *prompting*

En la literatura encontramos clasificaciones de las técnicas de *prompting* determinadas fundamentalmente por facetas funcionales y operativas, con un fuerte anclaje en el tipo de problema que se quiere resolver con el *prompt*: área de aplicación (por ejemplo, razonamiento y lógica, manejo de emociones y tono, entre otras) qué aspecto del LLM se quiere estimular o corregir (razonamiento secuencia, uso de conocimiento externo, autorreflexión...), estrategias de mitigación de problemas conocidos (alucinaciones, coherencia, fidelidad...) (Sahoo *et al.*, 2025). Otros autores basan su clasificación en facetas cognitivas, comunicativas y pragmáticas del uso de *prompts*: tipo de estrategia cognitiva o comunicativa empleada, rol del *prompt* en la interacción humano-modelo, grado de control frente a la salida, dimensión multimodal u orientación práctica y experiencial (Fagbohun *et al.*, 2024).

Si atendemos a la faceta cognitiva, funcional o interactiva que activan en el modelo, podemos clasificar las técnicas de *prompting* bajo las categorías que se recogen en la tabla 2, la cual, si bien no es totalmente exhaustiva, sí que presenta una amplia representación de las técnicas recogidas en la literatura.

Tabla 2. Técnicas de *prompting*.

Dimensión	**Subdimensión**	**Técnicas**	**Referencias**
Razonamiento y resolución estructurada	Razonamiento secuencial básico	*Zero-shot prompting* *Few-shot prompting*	Brown *et al.*, 2020; Harrison *et al.*, 2023; Kojima *et al.*, 2022; Radford *et al.*, 2019
	Razonamiento paso a paso	*Chain-of-thought (CoT)* *Automatic CoT* *Self-consistency*	Fagbohun *et al.*, 2024; Kojima *et al.*, 2022; Lyu *et al.*, 2023; Wang *et al.*, 2023; Wei *et al.*, 2022; Zhang *et al.*, 2022
	Razonamiento estructural	*Logical CoT (LogiCoT)* *Chain-of-symbol (CoS)* *Skeleton-of-thought (SoT)* *Layer-of-Thoughts (LoT) Prompting*	Fagbohun *et al.*, 2024; Fungwacharakorn *et al.*, 2024; Hu *et al.*, 2023; Ning *et al.*, 2023; Zhao *et al.*, 2023b
	Exploración de trayectorias	*Tree-of-thoughts (ToT)* *Graph-of-thoughts (GoT)* *Thread-of-thought (ThoT)* *Buffer of thoughts (BoT)*	Fagbohun *et al.*, 2024; Long, 2023; Yang *et al.*, 2024b; Yao *et al.*, 2023; Zhou *et al.*, 2023
	Razonamiento narrativo y sintético	*Narrative-of-thought (NoT)* *Chain of draft (CoD)*	Zhang *et al.*, 2024

Dimensión	Subdimensión	Técnicas	Referencias
Fiabilidad y verificación	Anclaje en conocimiento externo	*Retrieval-augmented generation (RAG)* *Chain-of-Knowledge (CoK)*	Lewis *et al.*, 2020; Li *et al.*, 2023a
	Verificación interna	*Chain-of-Verification (CoVe)* *Chain-of-Note (CoN)*	Dhuliawala *et al.*, 2023; Sahoo *et al.*, 2025; Yu *et al.*, 2024
	Contraste y corrección	*Contrastive CoT (CCoT)* *Responsive feedback prompting*	Chia *et al.*, 2023; Fagbohun *et al.*, 2024; Paul *et al.*, 2023; Zheng *et al.*, 2023
Metacognición y autorregulación	Refinamiento iterativo	*Self-refine prompting*	Madaan *et al.*, 2023
	Abstracción del problema	*Take a step back prompting*	Zheng *et al.*, 2023
	Reflexión sobre el proceso	*Self-reflection prompting* *Meta-Prompting*	Fagbohun *et al.*, 2024; Madaan *et al.*, 2023; Shinn *et al.*, 2023; Wang y Zhao, 2024
	Anticipación	*Anticipatory prompting*	Fagbohun *et al.*, 2024;
Contexto y dinámica conversacional	Contexto en ventana de atención	*In-Context prompting*	Dong *et al.*, 2024; Fagbohun *et al.*, 2024; Rubin *et al.*, 2021; Ye *et al.*, 2022
	Gestión del diálogo	*Conversational prompting* *Socratic prompting*	Chang, 2023; Fagbohun *et al.*, 2024; Liu *et al.*, 2023a; Wei *et al.*, 2023
	Gestión de roles	*Multi-Personas prompting*	Fagbohun *et al.*, 2024; Gu *et al.*, 2023
	Selección adaptativa	*Active prompting*	Diao *et al.*, 2023
Control del objetivo y del output	Clarificación semántica	*Rephrase and respond (RaR)*	Deng *et al.*, 2023
	Direccionamiento del output	*Show-me vs tell-me* *Target-your-response (TAR)*	Fagbohun *et al.*, 2024; Perez *et al.*, 2021; Zhao *et al.*, 2021
	Planificación macro	*Prompt macros* *End-goal planning*	Fagbohun *et al.*, 2024;
	Restricción formal	*Constrained vocabulary prompting*	Fagbohun *et al.*, 2024;
	Reformulación en código	*Code prompting* *Prompt to code*	Chen *et al.*, 2023; Fagbohun *et al.*, 2024; Puerto *et al.*, 2024

Dimensión	Subdimensión	Técnicas	Referencias
Dimensión afectiva y estilística	Emoción y tono	*Emotion prompting*	Li *et al.*, 2023b
Multimodalidad e interdisciplinariedad	Multimodalidad	*Multimodal prompting* *Visual prompting*	Bang *et al.*, 2023; Fagbohun *et al.*, 2024; Lee *et al.*, 2023
	Integración disciplinar	*Cross-disciplinary prompting*	Fagbohun *et al.*, 2024; Harrison *et al.*, 2023
	Contextualización	*Historical context prompting* *Modular prompting*	Fagbohun *et al.*, 2024; Liu *et al.*, 2023b
Creatividad y generación abierta	Exploración abierta	*Ambiguous prompting*	Fagbohun *et al.*, 2024;
	Creatividad guiada	*Directional stimulus prompting*	Fagbohun *et al.*, 2024; Shum *et al.*, 2023
	Inversión de roles	*Flipped interaction prompting*	Fagbohun *et al.*, 2024;
	Reescritura expresiva	*Grammar correction* (no puramente mecánica)	Fagbohun *et al.*, 2024;

En los siguientes apartados se explican con algo más de detalle cada una de las técnicas recogidas en la tabla anterior y se incluyen ejemplos centrados específicamente en ilustrar el funcionamiento de cada una de ellas. No obstante, en contextos reales de uso, estas técnicas no suelen aparecer de forma aislada, sino integradas en *prompts* más extensos y combinadas con otras estrategias, restricciones o elementos de contextualización.

3.1. Razonamiento y resolución estructurada de problemas

Esta dimensión agrupa técnicas de *prompting* diseñadas para inducir en el modelo procesos explícitos de **razonamiento**, **descomposición lógica** y **exploración sistemática de soluciones**, ya sea mediante razonamiento secuencial, estructurado, narrativo o multitrayectoria.[10] Mediante estas técnicas de procesamiento lógico y secuencial se espera que el LLM aborde tareas de razonamiento complejas y de múltiples pasos dividiéndolas en etapas manejables. Los métodos que se encuadran dentro de esta categoría se basan en la idea de fragmentar la tarea en componentes más pequeños, y cuentan con una justificación científica y matemática que respalda su aplicación. Estas metodologías no solo mejoran las capacidades de resolución de problemas de los modelos, sino que también proporcionan un marco para un razonamiento más intuitivo y "similar" al humano (Yu *et al.*, 2023).

Su objetivo principal es mejorar la capacidad del modelo para **abordar tareas complejas** que requieren **inferencias encadenadas**, **planificación** o **análisis paso a**

[10] El concepto "multitrayectoria" se refiere aquí a la capacidad inducida por el *prompt* para que el modelo genere, explore y evalúe más de una cadena de razonamiento posible antes de producir una respuesta final.

paso, sin modificar los parámetros del modelo. Entre las técnicas que podemos distinguir en esta categoría encontramos: *zero-shot prompting*, *few-shot prompting*, *chain-of-thought (CoT)*, *automatic CoT*, *self-consistency*, *logical CoT (LogiCoT)*, *chain-of-symbol (CoS)*, *skeleton-of-thought (SoT)*, *layer-of-thoughts (LoT)*, *tree-of-thoughts (ToT)*, *graph-of-thoughts (GoT)*, *thread-of-thought (ThoT)*, *buffer of thoughts (BoT)*, *narrative-of-thought (NoT)*, *chain of draft (CoD)*.

El ***prompting* de disparo cero** (*zero-shot prompting*), sin ejemplos o sin entrenamiento específico previo supone un cambio de paradigma en el uso de los LLM de gran tamaño, al prescindir de la necesidad de contar con amplios conjuntos de datos de entrenamiento. En su lugar, esta técnica se basa en instrucciones cuidadosamente diseñadas que orientan al modelo en la realización de tareas nuevas o no vistas previamente. En este enfoque, el modelo recibe una descripción explícita de la tarea dentro del *prompt*, sin disponer de ejemplos que establezcan correspondencias concretas entre entradas y salidas. A partir de ahí, el modelo explota el conocimiento adquirido durante su preentrenamiento para generar respuestas coherentes con la tarea planteada. (Harrison *et al.*, 2023; Kojima *et al.*, 2022; Radford *et al.*, 2019).

> **Ejemplo**
> *Interpreta los siguientes valores agregados (medias y desviaciones estándar) obtenidos en un estudio sobre la satisfacción de usuarios.*
> *Explica qué indican estos resultados de forma comprensible para un público no especializado en estadística.*
> *Evita tecnicismos innecesarios y no introduzcas conclusiones no sustentadas por los datos.*

En el ejemplo anterior, el modelo recibe solo la tarea y los datos, sin ejemplos de interpretaciones previas. Se confía en su capacidad para traducir indicadores estadísticos básicos a un lenguaje no especializado.

El ***prompting* de pocos disparos** o **con pocos ejemplos** (*few-shot prompting*) consiste en proporcionar al modelo un número reducido de ejemplos de pares entrada-salida con el objetivo de facilitar la comprensión de una tarea concreta (Brown *et al.*, 2020). Incluso la inclusión de unos pocos ejemplos bien seleccionados ha demostrado mejorar de forma significativa el rendimiento de los modelos en tareas complejas. Esta técnica implica el uso de *tokens* adicionales para incorporar dichos ejemplos, lo que puede resultar limitante cuando se trabaja con entradas de texto extensas. Asimismo, la selección y formulación de los ejemplos dentro del *prompt* pueden influir de manera notable en el comportamiento del modelo, por ejemplo, introduciendo sesgos (Brown *et al.*, 2020).

Ejemplo

Analiza el nivel de uso de los servicios digitales de una biblioteca pública a partir de los siguientes ejemplos.

Ejemplo 1

Datos:

- *Préstamos de libros electrónicos mensuales: 850*
- *Accesos a la biblioteca digital infantil: 2.400*

Análisis:

El número de accesos a la biblioteca digital infantil es notablemente superior al préstamo de libros electrónicos, lo que sugiere una alta demanda de recursos digitales orientados a público infantil y familiar, posiblemente vinculada a actividades educativas o de ocio supervisado.

Ejemplo 2

Datos:

- *Consultas al catálogo en línea: 7.200*
- *Renovaciones de préstamos en línea: 1.900*

Análisis:

La diferencia entre las consultas al catálogo y las renovaciones indica que el catálogo se utiliza principalmente como herramienta de exploración y búsqueda, mientras que la gestión activa de préstamos digitales presenta un uso más moderado.

Tarea

Aplica el mismo tipo de análisis al siguiente conjunto de datos:

Datos:

- *Reservas en línea de documentos físicos: 1.150*
- *Reservas presenciales de documentos físicos: 310*

En el ejemplo anterior, se incluyen dos ejemplos completos[11] de entrada-salida, adaptados al contexto de una biblioteca pública. Los ejemplos fijan el tipo de indicadores, el nivel interpretativo y el registro. El modelo debe reconocer el patrón analítico mostrado y reproducirlo en un nuevo caso, sin instrucciones adicionales sobre cómo razonar.

El ***prompting* de cadena de razonamiento** (*chain-of-thought* o CoT) provoca que el modelo "piense" de manera secuencial al procesar la información paso a paso (Wei *et al.*, 2022; Kojima *et al.*, 2022; Lyu *et al.*, 2023). En lugar de saltar directamente a una conclusión, esta técnica induce al modelo a tomarse un momento para descomponer consultas complejas en pasos intermedios explicables. Al hacer que el modelo "muestre su trabajo" y razone de forma lógica a través de cada etapa de la resolución de problemas, suele observarse un aumento general en la precisión de sus soluciones. Viene a solucionar las dificultades que los LLM presentan a la hora de abordar tareas que requieren razonamiento complejo (Wei *et al.*, 2022).

[11] Reducidos en este documento por razones de espacio.

Ejemplo

Analiza los siguientes datos de uso de una biblioteca pública y determina cuál de los servicios digitales presenta un mayor nivel de adopción relativa.
Explica tu razonamiento paso a paso antes de presentar la conclusión final.
Datos:

- *Usuarios activos totales de la biblioteca: 12.000*
- *Usuarios que han utilizado el préstamo digital al menos una vez: 2.400*
- *Usuarios que han utilizado el catálogo en línea al menos una vez: 6.600*
- *Usuarios que han utilizado el servicio de referencia virtual al menos una vez: 900*

Estructura tu respuesta en dos partes:

- *Razonamiento paso a paso*
- *Conclusión final*

En el ejemplo anterior, se solicita explícitamente que el modelo muestre el razonamiento intermedio, no solo el resultado. El análisis requiere varios pasos lógicos encadenados: 1) relacionar usuarios de cada servicio con el total, 2) comparar proporciones relativas, y 3) interpretar qué significa "mayor nivel de adopción". La estructura del *prompt* separa claramente proceso y resultado. Por otro lado, no se proporcionan ejemplos previos, por lo que el foco no está en el aprendizaje por imitación (*few-shot*), sino en la externalización del razonamiento. La técnica permite revisar la coherencia del análisis, detectar errores de interpretación, así como aumentar la transparencia del proceso.

El ***prompting* de cadena de razonamiento automático** (*automatic chain-of-thought* o *automatic CoT*) se basa en un enfoque que permite generar de forma automática cadenas de razonamiento a partir de instrucciones sencillas, como el *prompt* "vamos a pensar paso a paso", animando al modelo a explicar su razonamiento paso a paso sin necesidad de ejemplos previamente preparados (Zhang *et al.* 2022). En la práctica, el método selecciona diferentes preguntas y genera varias explicaciones alternativas para cada una, construyendo así un conjunto más amplio y variado de ejemplos. Este procedimiento reduce la probabilidad de errores sistemáticos y mejora el rendimiento del *few-shot prompting*, evitando al mismo tiempo el esfuerzo manual que supone crear cadenas de razonamiento de forma explícita (Sahoo *et al.*, 2025).

Ejemplo
Vamos a razonar paso a paso.
A partir de los siguientes resultados de un test de usabilidad en el sitio web de una institución cultural, identifica cuál es el principal problema de experiencia de usuario.
Datos:
- *Porcentaje de usuarios que completan una tarea sin ayuda: 42 %*
- *Tiempo medio de finalización de la tarea: 6 minutos*
- *Porcentaje de usuarios que abandonan antes de finalizar: 31 %*

Explica el razonamiento de forma ordenada antes de presentar la conclusión.

En el ejemplo anterior, no se define una estructura formal del razonamiento a diferencia del ejemplo aplicado a *CoT* ("Estructura tu respuesta en dos partes: razonamiento paso a paso y conclusión final"). Por otro lado, se utiliza un disparador genérico ("vamos a pensar paso a paso"). Por su parte, el modelo genera autónomamente la cadena de razonamiento: decide cuántos pasos, cómo organizarlos y cómo expresarlos.

El ***prompting* de consistencia interna** (*self-consistency*) es una estrategia de decodificación orientada a mejorar el rendimiento en tareas de razonamiento complejo, donde pueden existir múltiples trayectorias de razonamiento igualmente válidas. Esta técnica genera diversas cadenas de razonamiento alternativas, cada una siguiendo un camino lógico diferente (Wang *et al.*, 2022).

Ejemplo
A partir de los siguientes datos de una biblioteca universitaria, formula distintas interpretaciones razonadas sobre el grado de uso del repositorio institucional.
Tras considerar esas interpretaciones, indica cuál resulta más consistente con los datos disponibles.
Datos:
- *Descargas de documentos: 42.000*
- *Usuarios únicos del repositorio: 9.800*
- *Usuarios totales de la comunidad universitaria: 28.000*

En el ejemplo anterior, se solicita explícitamente la generación de múltiples razonamientos alternativos a partir de los mismos datos. Cada razonamiento sigue un camino lógico independiente. La respuesta final se basa en la consistencia entre las distintas cadenas de razonamiento, no en una única trayectoria. El objetivo es mejorar el rendimiento en tareas de razonamiento complejo, reduciendo la dependencia de una sola explicación potencialmente errónea.

El ***prompting* de cadena de razonamiento lógico** (*logical CoT* o *LogiCoT*) viene a intentar resolver las limitaciones del *chain-of-thought prompting* en lo que respecta a la verificación de la corrección de los razonamientos. Este enfoque alternativo de carácter

neurosimbólico integra principios de lógica simbólica con el fin de promover un razonamiento más coherente y estructurado (Zhao *et al.*, 2023b). A través de un ciclo iterativo de pensar-verificar-revisar, este enfoque contribuye a reducir errores lógicos y alucinaciones (Sahoo *et al.*, 2025).

Ejemplo
Analiza el siguiente argumento sobre la arquitectura de la información de un sitio web institucional.

1. *Identifica la conclusión planteada.*
2. *Comprueba si las premisas conducen lógicamente a esa conclusión.*
3. *Revisa el razonamiento si detectas saltos lógicos.*[12]

Premisas:

- *El 70 % de los usuarios accede al contenido desde el menú principal.*
- *El menú principal contiene más de 12 opciones de primer nivel.*

Conclusión inicial:
"La arquitectura de la información es clara y eficiente."

En el ejemplo anterior, el *prompt* introduce explícitamente un proceso de verificación del razonamiento, no solo su exposición. El razonamiento se articula en un ciclo iterativo de pensar, verificar y revisar. Se emplean criterios lógicos básicos para comprobar si las conclusiones se derivan correctamente de las premisas. El objetivo es detectar y corregir errores lógicos, alineándose con la función del *LogiCoT* de reducir razonamientos incorrectos o poco fundamentados.

El ***prompting* de cadena de símbolos** (*chain-of-symbol* o CoS) consiste en una técnica que sustituye el lenguaje natural por representaciones simbólicas condensadas como soporte del razonamiento (Hu *et al.*, 2023). Esto permite construir *prompts* más claros y concisos, refuerza la capacidad de razonamiento espacial de los modelos y facilita la interpretación humana de los procesos de razonamiento. No obstante, también plantea desafíos importantes, entre ellos la escalabilidad del enfoque, su capacidad de generalización, la integración con otras técnicas de *prompting* y la interpretación del razonamiento simbólico generado por el modelo (Sahoo *et al.*, 2025).

[12] Por ejemplo, cuando el modelo afirma una conclusión, sin que esta se derive de forma necesaria o justificada de las premisas o datos proporcionados.

Ejemplo
Modela el siguiente razonamiento sobre la arquitectura de la información utilizando símbolos.
Leyenda:
- *M = número de opciones de menú*
- *T = tasa de éxito de tareas*
- *A = tasa de abandono*

Datos:
- *M > 10*
- *T = 45 %*
- *A = 35 %*

Objetivo:
Representar simbólicamente la relación entre complejidad del menú y desempeño del usuario.

En el ejemplo anterior, la forma de razonamiento (no necesariamente todo el *prompt*) no se articula en lenguaje natural, sino mediante representaciones simbólicas condensadas. Se utilizan símbolos definidos explícitamente en el propio *prompt* como soporte del razonamiento. El foco no está en narrar o explicar, sino en estructurar el razonamiento de forma abstracta y compacta.

El ***prompting* de esqueleto de razonamiento** (*skeleton-of-thought* o SoT) proporciona al modelo un "esqueleto" o estructura de alto nivel que debe completar. Este enfoque permite al modelo generar contenido en paralelo dentro de secciones previamente definidas, manteniendo al mismo tiempo una organización clara y coherente (Ning *et al.*, 2023). Al ofrecer una estructura previa, se reduce el riesgo de desviaciones irrelevantes y se mejora la consistencia global de la salida generada (Fagbohun *et al.*, 2024).

Ejemplo
Para redactar un correo electrónico, se puede proporcionar al modelo un esquema como:
[Saludo] – [Introducción del tema] – [Cuerpo principal] – [Cierre] – [Firma]

En el ejemplo anterior, el modelo completa cada sección respetando la estructura de alto nivel indicada, produciendo un resultado bien organizado y alineado con el propósito comunicativo.

El ***prompting* de capas de razonamiento** (*layer-of-thoughts* o LoT) introduce un marco jerárquico de razonamiento que emplea jerarquías de restricciones para estructurar el proceso inferencial, con el objetivo de mejorar tanto la precisión en la recuperación de la información como la interpretabilidad de los resultados (Fungwacharakorn *et al.*, 2024). Utilizado en el ámbito de la recuperación de documentos legales, el LoT organiza el razonamiento en distintos niveles, diferenciando entre pensamientos de capa y pensamientos de opción, y aplica restricciones de forma

secuencial para filtrar y refinar progresivamente las respuestas candidatas (Sahoo *et al.*, 2025).

Ejemplo
Analiza la calidad de un sitio web institucional aplicando un razonamiento por capas jerárquicas.
Capa 1 – Accesibilidad
Evalúa el grado de cumplimiento de los criterios de accesibilidad más relevantes y determina si existen barreras críticas.
Capa 2 – Usabilidad
Analiza los resultados de los test conducidos para identificar problemas de usabilidad.
Capa 3 – Experiencia global
Integra los resultados de las capas anteriores para valorar la experiencia de usuario del sitio web.
Datos disponibles:
- *Accesibilidad*
  - *Cumplimiento WCAG 2.1 nivel A: completo*
  - *Cumplimiento WCAG 2.1 nivel AA: parcial*
  - *Errores de contraste detectados: 14*
  - *Formularios sin etiquetas asociadas: 3*
  - *[…]*
- *Usabilidad*
  - *Tasa de éxito de tareas: 47 %*
  - *Tiempo medio de realización de tareas: 5 minutos y 40 segundos*
  - *Tasa de abandono antes de completar la tarea: 33 %*
  - *Solicitudes de ayuda durante la prueba: 41 % de los usuarios*
  - *[…]*

Contexto de uso
- *Acceso desde dispositivos móviles: 62 %*
- *Acceso desde escritorio: 38 %*

En el ejemplo anterior, el razonamiento sigue organizado en capas jerárquicas. Cada capa introduce nuevas restricciones y refina progresivamente la interpretación de la capa anterior.

El ***prompting* de árbol de razonamientos** (*tree-of-thoughts* o ToT) y el de grafo de razonamientos (*graph-of-thoughts* o GoT) extienden el razonamiento secuencial lineal hacia estructuras más ramificadas. En lugar de seguir una única cadena de pensamiento, estas técnicas permiten al modelo explorar múltiples trayectorias de razonamiento en paralelo, evaluando diferentes alternativas o escenarios posibles (Besta *et al.*, 2023; Long, 2023; Fagbohun *et al.*, 2024; Yao *et al.*, 2023). El ToT organiza estas trayectorias en forma de árbol, mientras que el GoT permite conexiones más complejas entre ideas,

representadas como un grafo. Ambas aproximaciones amplían los métodos secuenciales tradicionales para alinearse mejor con las características no lineales del pensamiento humano (Sahoo *et al.*, 2025).

> **Ejemplos ToT:**
> *Analiza distintas opciones para mejorar el servicio de referencia virtual de una biblioteca pública.*
> *Explora varias alternativas posibles de forma independiente y analiza para cada una sus ventajas y limitaciones antes de formular una conclusión final.*
> *Considera, al menos, las siguientes dimensiones:*
> - *Accesibilidad del servicio,*
> - *Carga de trabajo del personal,*
>
> *Calidad de la atención al usuario*
> **Ejemplo GoT:**
> *Examina las relaciones entre los distintos componentes del sistema de información de una biblioteca universitaria.*
> *Considera las interdependencias entre:*
> - *Repositorio institucional*
> - *Sistemas de descubrimiento*
> - *Políticas de acceso abierto*
> - *Apoyo a la investigación*
>
> *Analiza el problema teniendo en cuenta conexiones cruzadas entre estos elementos, no como procesos independientes.*

En el primer ejemplo anterior, este tipo de instrucción anima al modelo a considerar diversas posibilidades antes de converger en una solución final. Cada alternativa constituye una rama independiente de razonamiento, analizada por separado. El objetivo no es solo razonar paso a paso, sino comparar escenarios posibles antes de converger en una decisión. En el segundo caso, el razonamiento no se organiza como un árbol jerárquico ni como una secuencia lineal. Por otro lado, se invita explícitamente al modelo a considerar conexiones cruzadas entre distintos elementos del problema.

El *prompting* de **hilo de razonamiento** (*thread-of-thought* o ThoT) es una técnica de *prompting* inspirada en la cognición humana que busca mejorar el razonamiento mediante el análisis progresivo de la información. En lugar de procesar el contexto de forma global, el ThoT lo descompone sistemáticamente en segmentos manejables, lo que permite un razonamiento incremental y más controlado (Zhou *et al.*, 2023).

Ejemplo
Analiza el siguiente informe sobre el uso de servicios de una biblioteca pública aplicando el siguiente procedimiento:
- *Resume y analiza cada apartado del informe por separado.*
- *A continuación, integra los resultados parciales para formular una interpretación global del uso de los servicios.*

Informe:
- *Apartado 1: Datos de uso del préstamo digital*
- *Apartado 2: Datos de uso del catálogo en línea*
- *Apartado 3: Datos del servicio de referencia virtual*

El enfoque se articula en un proceso de dos fases. En primer lugar, el modelo resume y analiza cada segmento de manera individual en partes más manejables, posteriormente, integra y refina la información obtenida para generar una respuesta final coherente. Esta técnica favorece un razonamiento incremental y controlado, especialmente adecuado para contextos extensos o complejos. Una de las principales fortalezas de esta técnica es su flexibilidad, ya que puede incorporarse como un módulo y mejorar el razonamiento en distintos modelos y en combinación con otros métodos de *prompting* (Sahoo *et al.*, 2025).

El ***buffer* de razonamientos** (*buffer of thoughts* o BoT) introduce un enfoque orientado a mejorar el razonamiento de los LLM mediante el uso de patrones de razonamiento reutilizables de alto nivel, con el objetivo de equilibrar universalidad, eficiencia y robustez. En lugar de generar razonamientos desde cero para cada consulta, el BoT almacena y reutiliza estructuras de razonamiento previamente aprendidas que pueden adaptarse a distintas tareas. El método se apoya en dos componentes principales: un *meta-buffer*, que actúa como repositorio de patrones de razonamiento abstractos, y un gestor dinámico, encargado de recuperar y adaptar las plantillas más adecuadas en función de la tarea planteada (Yang *et al.*, 2024b).

Ejemplo
Meta-buffer (plantilla guardada)
"Ordenar + punto de corte (h)"
- Reúne la lista de citas por publicación.
- Ordena de mayor a menor: $c_1 \geq c_2 \geq \cdots \geq c_n$
- Recorre las posiciones $i = 1..n$ y busca el mayor i tal que $c_i \geq i$
- Devuelve $h = i$
- Verificación final: verifica el "borde": $c_h \geq h$ y (si existe) $c_h + 1 < h + 1$

Prompt
Una investigadora tiene 8 artículos con estas citas: 25,10,8,5,4,3,1,0 ¿Cuál es su índice h?"

El ***prompting* de narrativas de razonamiento** (*narrative-of-thought* o NoT) se orienta a abordar el razonamiento temporal. Para ello, introduce una estrategia de *prompting* que mejora la capacidad del modelo para razonar sobre secuencias temporales

sin necesidad de un entrenamiento adicional. El enfoque se basa en estructurar la información y el razonamiento de forma narrativa, facilitando la comprensión de relaciones temporales complejas (Zhang *et al.*, 2024). La técnica se articula en torno a tres componentes fundamentales. En primer lugar, emplea una representación estructurada de la información que puede implementarse mediante clases en Python u otros formatos estructurados (tabular, etc.), que permite modelar explícitamente eventos y relaciones temporales. En segundo lugar, utiliza una plantilla de *prompting* con un enfoque narrativo que guía al modelo en la construcción del razonamiento. Por último, incorpora demostraciones alineadas con la narrativa, lo que refuerza la coherencia temporal del razonamiento generado. En conjunto, esta combinación permite mejorar de forma efectiva el razonamiento temporal de los LLM sin modificar sus parámetros internos (Sahoo *et al.*, 2025).

Ejemplo

1) Representación estructurada de eventos y relaciones temporales

Evento 1 (2019)

- *Hecho: Implantación del repositorio institucional de una universidad.*
- *Consecuencia: Se crea por primera vez una infraestructura formal para el acceso abierto a la producción científica.*

Evento 2 (2020)

- *Hecho: Aprobación de una política institucional de acceso abierto.*
- *Consecuencia: El depósito de publicaciones pasa de ser voluntario a estar recomendado institucionalmente.*

Relación temporal:

- *La política institucional se apoya en la infraestructura creada con la implantación previa del repositorio.*

Evento 3 (2021)

- *Hecho: Integración del repositorio institucional con los sistemas de evaluación académica.*
- *Consecuencia: El depósito de publicaciones comienza a tener impacto directo en los procesos de evaluación del personal investigador.*

Relación temporal:

- *La integración solo es posible tras la existencia de una política institucional que legitima el uso del repositorio.*

Evento 4 (2022)

- *Hecho: Puesta en marcha de campañas de formación dirigidas al personal investigador.*
- *Consecuencia: Mejora tanto el volumen como la calidad de los depósitos realizados.*

Relación temporal:

- *Las acciones formativas responden a los problemas detectados tras el aumento del uso del repositorio en fases anteriores.*

2) Plantilla de prompting con enfoque narrativo
A partir de los eventos descritos, construye una narración razonada que explique la evolución temporal de la política de acceso abierto en la universidad.
Relata los acontecimientos en orden cronológico, explicando cómo cada evento condiciona el siguiente y cómo se va consolidando el proceso a lo largo del tiempo.
Presenta el razonamiento como una narración coherente en prosa, evitando listas o esquemas.
3) Demostración alineada con la narrativa (ejemplo previo que sirve de guía)
Demostración:
En una fase inicial, la implantación del repositorio institucional permitió establecer una base técnica para el acceso abierto, aunque su adopción fue todavía limitada. Posteriormente, la aprobación de una política institucional formalizó este compromiso y favoreció un aumento progresivo de los depósitos. Con el paso del tiempo, la integración del repositorio en los sistemas de evaluación académica transformó esta tendencia en un crecimiento sostenido, al vincular el acceso abierto con incentivos profesionales. Finalmente, las campañas de formación contribuyeron a consolidar el modelo, mejorando no solo la cantidad, sino también la calidad de los contenidos depositados.
4) Tarea solicitada al modelo (instanciación)
Utilizando la misma lógica narrativa que en el ejemplo anterior, explica la evolución del proceso descrito en los eventos proporcionados, destacando la relación temporal y causal entre ellos.

En el ejemplo anterior, los eventos están claramente delimitados y las relaciones temporales y de dependencia son explícitas. Por otro lado, mediante la plantilla el modelo es guiado para razonar en forma de narración temporal, priorizando la coherencia cronológica y causal. Finalmente, el ejemplo previo muestra cómo articular la historia de forma coherente.

El ***prompting* de cadena de borradores** (c*hain of draft* o CoD) (Xu *et al.*, 2025) es una estrategia diseñada para mejorar la eficiencia del razonamiento. A diferencia de CoT, CoD genera salidas concisas y densas en información en cada paso, reduciendo el consumo de *tokens* y la latencia sin sacrificar precisión.

Ejemplo
Evalúa los resultados de una prueba de usabilidad mediante una cadena de borradores concisos.

- *Borrador 1: identifica únicamente los indicadores críticos.*
- *Borrador 2: expresa la conclusión principal en una frase a basada únicamente en el borrador 1.*

Datos:

- *Tasa de éxito de tareas: 46 %*
- *Tasa de abandono: 34 %*
- *[...]*

El razonamiento se desarrolla en borradores sucesivos, no en una cadena extensa de explicaciones. Cada borrador es intencionalmente breve y denso en información. El segundo borrador se apoya exclusivamente en el anterior, refinando el resultado sin reexplicar el proceso. El enfoque permite mantener la precisión del razonamiento con menor coste computacional que el método CoT.

3.2. Fiabilidad y verificación

Esta dimensión agrupa técnicas de *prompting* orientadas a mejorar la **fiabilidad**, la **factualidad** y la **robustez de las respuestas generadas** por los LLM, abordando de forma explícita uno de sus principales límites: la generación de contenidos incorrectos, incompletos o no verificables, comúnmente descritos como alucinaciones. A diferencia de las técnicas centradas en el razonamiento interno del modelo, este conjunto de enfoques introduce mecanismos de contraste, verificación, validación externa o retroalimentación iterativa, con el objetivo de reforzar la calidad epistémica de las salidas.

Las técnicas incluidas en esta categoría se apoyan en estrategias como la incorporación de conocimiento externo, la verificación paso a paso de las respuestas, la evaluación crítica de los propios razonamientos del modelo o la corrección guiada mediante *feedback*. Mediante estos mecanismos, se busca que el LLM no solo genere una respuesta plausible, sino que pueda justificarla, contrastarla o revisarla, aproximándose a prácticas humanas de comprobación y validación de la información. Este enfoque resulta especialmente relevante en contextos sensibles o de alto riesgo, como la investigación académica, la educación, la salud, el ámbito jurídico o la toma de decisiones informadas.

Entre las técnicas que se encuadran en esta categoría se incluyen: *retrieval-augmented generation (RAG)*, *chain-of-knowledge (CoK)*, *chain-of-verification (CoVe)*, *chain-of-note (CoN)*, *contrastive CoT (CCoT)* y *responsive feedback prompting*.

La **generación aumentada por recuperación** (*retrieval-augmented generation* o RAG) integra de forma directa la recuperación de información en el proceso de generación mediante *prompts* (Lewis *et al.*, 2020). Con esta técnica se busca mitigar la dependencia de datos de entrenamiento y su posible falta de actualización, pertinencia o calidad, la cual dificulta la producción de respuestas precisas en tareas que requieren acceso a conocimiento externo o actualizado. En estos escenarios, el *prompting* tradicional resulta insuficiente y, en muchos casos, obliga a recurrir a costosos procesos

de reentrenamiento (Sahoo *et al.*, 2025). El enfoque RAG analiza la entrada del usuario, formula una consulta específica y recupera información relevante desde una base de conocimiento previamente construida. Los fragmentos obtenidos se incorporan al *prompt* original, enriqueciéndolo con contexto adicional. Este *prompt* aumentado permite al modelo generar respuestas que combinan creatividad con mayor precisión factual.

> **Ejemplo**
> *Utilizando los siguientes documentos institucionales recuperados, describe las obligaciones del personal investigador respecto al depósito de publicaciones en el repositorio institucional.*
> *Basa la respuesta únicamente en los textos proporcionados.*
> *Documentos recuperados* [documentos adjuntos]*:*
> - *Política institucional de acceso abierto*
> - *Guía de depósito en el repositorio*

En el ejemplo anterior, podemos hablar de un caso de RAG manual en el que es el usuario quien selecciona los documentos y los proporciona directamente en el *prompt* para exigir una respuesta que se base en ellos.

El ***prompting* de cadena de conocimiento** (*chain-of-knowledge* o CoK) plantea un enfoque que descompone sistemáticamente las tareas complejas en pasos coordinados. El proceso se inicia con una fase de preparación del razonamiento, en la que se delimita el contexto y se formula con precisión el problema. A continuación, el modelo entra en una etapa dinámica de adaptación del conocimiento, en la que recopila y contrasta evidencias procedentes de múltiples fuentes, incluyendo su conocimiento interno, recursos externos y la información aportada en el propio *prompt* (Li *et al.*, 2023a).

> **Ejemplo**
> *Explica por qué un sitio web institucional debe cumplir determinados criterios de accesibilidad, enlazando de forma explícita los distintos niveles normativos que lo justifican.*
> *Organiza las afirmaciones de forma que cada una se apoye en la anterior, evitando afirmaciones no fundamentadas.*
> *Para cada afirmación relevante, indica explícitamente el documento, norma o fuente de la que procede.*
> *Información disponible* [documentos adjuntos]*:*
> - *Directiva (UE) 2016/2102 del Parlamento Europeo y del Consejo, de 26 de octubre de 2016, relativa a la accesibilidad de los sitios web y aplicaciones para dispositivos móviles de los organismos del sector público.*
> - *España. Real Decreto 1112/2018, de 7 de septiembre, sobre accesibilidad de los sitios web y aplicaciones para dispositivos móviles del sector público. Boletín Oficial del Estado, núm. 217, de 8 de septiembre de 2018, pp. 88444–88462.*

— *World Wide Web Consortium (W3C). (2018). Web Content Accessibility Guidelines (WCAG) 2.1. W3C Recommendation, 5 June 2018.*

En el ejemplo anterior, el foco no está en el razonamiento interno del modelo, sino en la organización explícita del conocimiento. La respuesta se construye como una cadena de piezas informativas enlazadas, donde cada una fundamenta la siguiente. Se hace visible de dónde procede cada afirmación, reforzando la fiabilidad y trazabilidad del contenido generado. Esta técnica resulta especialmente útil en contextos normativos, institucionales o donde la justificación documental es clave.

El ***prompting* de cadena de verificación** (*chain-of-verification* o CoVe) busca mitigar el problema de las alucinaciones en los LLM mediante un enfoque que introduce un proceso estructurado de verificación interna en varias etapas. En concreto, el método se articula en cuatro pasos: (1) el modelo genera una respuesta inicial, (2) formula de manera explícita preguntas de verificación destinadas a comprobar la validez de su propio razonamiento, (3) responde a dichas preguntas de forma independiente, y (4) produce una respuesta final revisada que integra los resultados del proceso de verificación (Dhuliawala *et al.*, 2024). El CoVe emula los mecanismos humanos de comprobación y revisión, contribuyendo a mejorar la coherencia y la precisión de las salidas generadas.

Ejemplo
Paso 1 (respuesta inicial)
Explica cuáles suelen ser las obligaciones del personal investigador respecto al depósito de publicaciones en el repositorio institucional.
Paso 2 (cadena de verificación)
Identifica las afirmaciones clave (por ejemplo: obligatoriedad, plazos, tipos de documentos, excepciones) que requieren verificación.
Paso 3 (comprobación interna)
Evalúa cada afirmación y determina si está plenamente justificada por lo que has dicho o si has introducido supuestos.
Paso 4 (versión final)
Produce una versión final depurada, eliminando o matizando lo no verificado.

En el ejemplo anterior, se separan explícitamente una respuesta inicial de un proceso posterior de verificación en cadena. La verificación no se plantea como una única revisión general, sino como una secuencia de comprobaciones sobre afirmaciones clave. El resultado final es una respuesta revisada, donde se depura lo no verificado y se intentan eliminar todas las incertidumbres.

El ***prompting* de cadena de notas** (*chain-of-note* o CoN) aplica un enfoque orientado a mejorar la robustez de los documentos en implementaciones RAG mediante

un proceso sistemático de evaluación de la relevancia de los documentos recuperados, priorizando la información crítica y fiable y filtrando el contenido que no resulta pertinente (Yu *et al.*, 2023). Este método se centra en generar notas de lectura secuenciales que sirven como una capa de razonamiento adicional entre los documentos recuperados y la respuesta final (Greyling, 2023).

Ejemplo
Pregunta:
¿Puede una biblioteca pública limitar el acceso al préstamo digital a determinados perfiles de usuarios?
Documentos recuperados (o pasados al LLM):

- *Reglamento de uso de bibliotecas públicas (artículos 2–6)*
- *Política municipal de servicios digitales*
- *Nota de prensa sobre actividades culturales digitales*

Instrucciones (CoN):
Lee cada documento y redacta notas breves indicando qué información es relevante para responder a la pregunta.
Clasifica cada documento como:

a) responde directamente a la pregunta,
b) aporta contexto útil pero no una respuesta directa,
c) no es relevante para la pregunta.

Y justifica el uso o descarte de cada documento.
Elabora la respuesta final solo a partir de las notas relevantes.
Si ningún documento permite responder con seguridad, indícalo explícitamente.

En el ejemplo anterior, en vez de pasar directamente los documentos recuperados al modelo para que construya la respuesta, CoN instruye al LLM a leer esos textos primero y generar notas de lectura que capturen los puntos clave, permitan evaluar la relevancia de cada fragmento respecto a la consulta e identifiquen qué partes son útiles y cuáles no. En este caso en concreto, teóricamente se evitaría que el modelo use la nota de prensa (ruido). Además, se obliga a justificar el uso de descarte de cada documento. Sus principales limitaciones son que los documentos recuperados (o pasados al LLM) pueden no incluir una respuesta clara y, por otro lado, la recuperación de información puede incluir fragmentos irrelevantes o fuera de dominio.

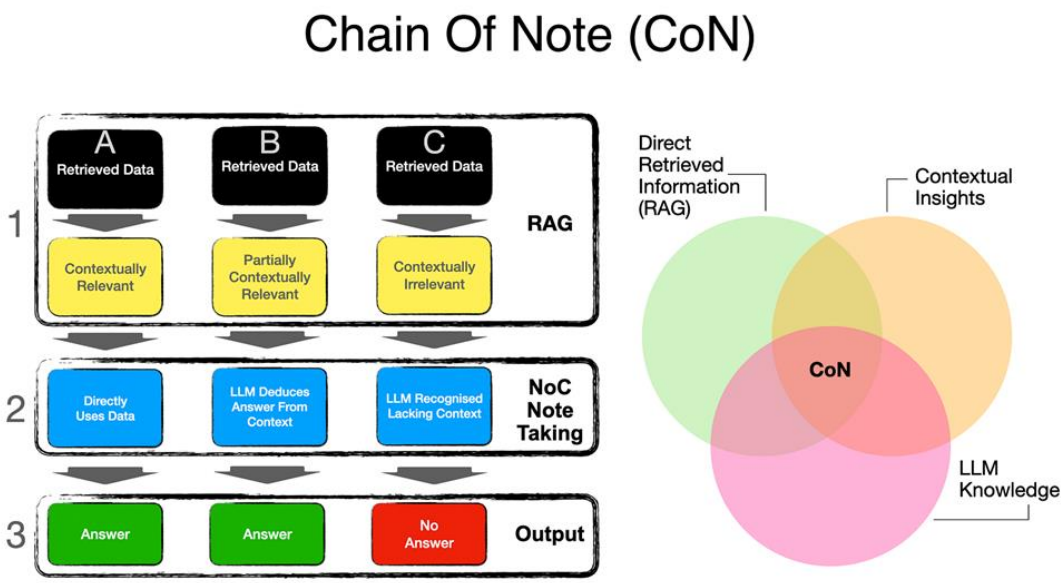


Figura 1. Síntesis del método *chain-of-note* (CoN). Fuente: Greyling, 2023.

El ***prompting* de cadena de razonamiento contrastiva** (*contrastive CoT* o CCoT) aborda la carencia de aprender a partir de los errores presentes en la técnica CoT. Con este enfoque se complementa los *prompts* convencionales con demostraciones de razonamiento tanto correctas como incorrectas (Chia *et al.*, 2023).

Ejemplo
Prompt
Una biblioteca universitaria dispone de 90.000 € para recursos electrónicos.
Se asignan 40.000 € a revistas electrónicas.
Del presupuesto restante, se reserva un 25 % para renovaciones.
¿Cuánto presupuesto queda disponible?
Explicación correcta
- *Restante: 90.000 − 40.000 = 50.000*
- *Reserva: 50.000 × 0,25 = 12.500*
- *Disponible: 50.000 − 12.500 = 37.500 €*

Explicación incorrecta
Se reserva el 25 % del total inicial (22.500 €).
Este razonamiento es incorrecto porque:
- *Aplica el porcentaje al total inicial en lugar de al presupuesto restante.*

Pregunta
A partir del presupuesto correctamente calculado, la biblioteca decide destinar 15.000 € adicionales a nuevas bases de datos
¿Cuánto presupuesto queda finalmente sin asignar?
Salida
Presupuesto disponible inicial: 37.500 €
Tras la nueva asignación: 37.500 − 15.000 = 22.500 €

El ***prompting* con retroalimentación adaptativa** (*responsive feedback prompting*) consiste en proporcionar retroalimentación directa al modelo inmediatamente después de que haya generado una respuesta. Esta retroalimentación se utiliza para guiar la siguiente salida del modelo, refinando progresivamente el resultado (Paul *et al.*, 2023; Zheng *et al.*, 2023).

> **Ejemplo**
> *El contenido es correcto, pero necesito que se destaque mejor qué pasos son obligatorios y cuáles opcionales.*

Ante esta petición el modelo ajusta el documento reorganizando la estructura y marcando explícitamente los pasos críticos.

3.3. Metacognición y autorregulación

Las técnicas de **metacognición** y **autorreflexión** se centran en **mejorar las capacidades asistenciales** de los LLM mediante *prompts* introspectivos, la anticipación de necesidades del usuario y la generación de código. Estas técnicas fomentan que el modelo evalúe, revise o amplíe sus propias respuestas (Fagbohun *et al.*, 2024; Wang y Zhao, 2024).

Las técnicas introducidas en esta sección incluyen: *self-refine prompting*, *take a step back prompting*, *self-reflection prompting*, y el *meta-Prompting* y *anticipatory prompting*.

El ***prompting* de autorefinamiento** (*self-refine prompting*) es una técnica orientada a mejorar el rendimiento de los LLM mediante un proceso de refinamiento iterativo de las respuestas, basado en retroalimentación generada por el propio modelo y análogo a los procesos de revisión humana. Aunque los LLM son capaces de abordar una amplia variedad de tareas, suelen presentar limitaciones cuando se enfrentan a objetivos complejos, metas poco definidas o razonamientos que requieren múltiples pasos, lo que puede dar lugar a respuestas iniciales imprecisas o con fallos lógicos. Inspirado en los mecanismos de revisión iterativa propios de la cognición humana, esta técnica introduce un procedimiento estructurado en tres etapas: en primer lugar, el modelo genera una respuesta inicial; a continuación, se le induce a evaluar críticamente su propia salida; finalmente, se le pide que refine la respuesta a partir de esa retroalimentación. Este ciclo se repite hasta que se alcanzan criterios de parada previamente establecidos, lo que permite obtener resultados progresivamente más precisos y mejor ajustados al contexto (Madaan *et al.*, 2023; Sahoo *et al.*, 2025).

El ***prompting* de dar un paso atrás** (*take a step back prompting*) busca afrontar el reto persistente del razonamiento complejo de múltiples pasos mediante un mecanismo explícito de abstracción, que permite al modelo extraer conceptos de alto nivel y principios generales a partir de casos concretos antes de abordar la resolución del problema (Zheng *et al.*, 2023). La técnica se articula en un procedimiento de dos etapas que combina abstracción y razonamiento dirigido. En primer lugar, el modelo "da un paso atrás" (*step back*) para identificar las ideas generales o los principios subyacentes al problema planteado. En una segunda fase, estas abstracciones se utilizan como guía

para estructurar el razonamiento posterior y resolver la tarea original de manera más eficaz y fundamentada (Sahoo *et al.*, 2025).

El ***prompting* de autorreflexión** instruye al modelo para que revise críticamente una respuesta previa, evaluando su precisión o coherencia (Madaan *et al.*, 2023; Shinn *et al.*, 2023).

> **Ejemplo**
> Tras proporcionar una respuesta sobre una cuestión ética compleja, se puede preguntar al modelo:
> *¿Estás seguro de esta respuesta?*
> lo que induce una reevaluación y posible corrección.

El ***meta-prompting*** implica pedir al modelo que analice el propio proceso de *prompting* o la efectividad de los *prompts* utilizados, con el objetivo de sugerir mejoras (Wang y Zhao, 2024). Sirve para reducir ambigüedades, mejorar la precisión, adaptar el tono y nivel, incluir restricciones adicionales útiles o crear plantillas reutilizables. Es posible proponer simplemente mejoras, o solicitar que defina formatos de salida, identifique lagunas o añada criterios de calidad específicos.

> **Ejemplo**
> *Analiza la efectividad de los últimos cinco prompts y sugiere cómo podrían mejorarse para obtener resultados más precisos.*

El ***prompting* de anticipación** (*anticipatory prompting*) anima al modelo a anticipar preguntas o necesidades adicionales del usuario y a proporcionar información complementaria relevante junto con la respuesta principal.

> **Ejemplo**
> Ante la pregunta:
> *¿Qué resolución debo usar para escanear documentos?*
> el modelo puede indicar una resolución estándar y anticipar necesidades adicionales incluyendo consideraciones sobre el tipo de documento (texto, fotografía), el formato de salida, el uso de OCR y el impacto en el tamaño del archivo.

3.4. Contexto y dinámica conversacional

Las técnicas de **comprensión contextual** y **memoria** se centran en permitir que los LLM recuerden y hagan referencia a **interacciones pasadas** con el fin de ofrecer experiencias **conversacionales fluidas** y garantizar la **coherencia** y la **relevancia** en diálogos prolongados. Estas técnicas aprovechan el contexto proporcionado dentro de un *prompt* o a lo largo de una interacción para mantener la continuidad temática y semántica de las respuestas del modelo. Al incorporar información previa o instrucciones acumulativas, estas técnicas permiten que los LLM produzcan respuestas más alineadas con las

expectativas del usuario y con el flujo general de la conversación. Este enfoque resulta especialmente valioso en aplicaciones conversacionales, donde la pérdida de contexto puede dar lugar a respuestas inconexas o redundantes (Fagbohun *et al.*, 2024).

Entre las técnicas que podemos distinguir en esta categoría encontramos: *in-context prompting*, *conversational prompting*, *socratic prompting*, *multi-personas prompting* y *active prompting*.

El ***prompting* en contexto** (*in-context prompting*) aprovecha la capacidad del modelo para utilizar información proporcionada anteriormente dentro de la ventana de contexto. Al incluir interacciones previas o datos relevantes en el *prompt*, el modelo puede "recordar" y reutilizar esta información para generar respuestas coherentes y contextualmente apropiadas (Dong *et al.*, 2024; Fagbohun *et al.*, 2024; Rubin *et al.*, 2021; Ye *et al.*, 2022).

> **Ejemplo**
> Un usuario explica inicialmente que está evaluando el impacto del uso de un *framework* CSS en el web de una biblioteca universitaria. Más adelante, al preguntar:
> *¿Qué consecuencias puede tener esto a largo plazo?*
> el modelo tiene en cuenta el contexto previo y discute implicaciones en accesibilidad, mantenimiento, rendimiento y dependencia tecnológica, sin que el usuario tenga que reiterar el ámbito ni los objetivos del análisis.

El ***prompting* conversacional** (*conversational prompting*) estructura la interacción como un diálogo continuo, en el que cada respuesta del modelo puede dar lugar a nuevas preguntas o aclaraciones por parte del usuario. Esta técnica fomenta una interacción iterativa que permite refinar progresivamente las respuestas y profundizar en un tema determinado (Fagbohun *et al.*, 2024; Liu *et al.*, 2023a).

> **Ejemplo**
> El usuario pregunta inicialmente qué significa que una biblioteca digital sea accesible. Tras la respuesta, plantea cómo comprobar si su web cumple con las WCAG. A partir de ahí, pregunta qué errores son más frecuentes y cómo priorizar las correcciones. La interacción conversacional permite profundizar paso a paso en un tema técnico complejo.

El ***prompting* socrático** (*socratic prompting*) se inspira en el método socrático y utiliza una secuencia de preguntas para guiar el razonamiento del modelo y profundizar en un concepto. En lugar de proporcionar respuestas directas, el modelo formula o responde a preguntas que conducen gradualmente hacia una comprensión más profunda del tema (Chang, 2023; Fagbohun *et al.*, 2024).

Ejemplo
Para reflexionar sobre la automatización en bibliotecas, se puede plantear:
¿Qué tareas bibliotecarias son susceptibles de automatización?
seguido de preguntas como:
¿Qué se gana y qué se pierde al delegar decisiones en sistemas automáticos? O *¿Dónde debería situarse la responsabilidad profesional?*, favoreciendo un análisis crítico del impacto tecnológico.

El ***prompting* de múltiples personas** (*multi-personas prompting*) implica instruir al modelo para que adopte múltiples perspectivas, roles o Personas al generar respuestas. Esta técnica permite explorar diferentes puntos de vista o estilos comunicativos dentro de una misma interacción (Gu *et al.*, 2023; Fagbohun *et al.*, 2024).

Ejemplo
Se puede pedir al modelo que redacte una explicación sobre las normas de préstamo "*como las comunicaría un bibliotecario en el mostrador de atención al público"* y luego "*como la presentaría un responsable de la biblioteca en un documento institucional"*.
El modelo adapta el tono, la extensión y el grado de formalidad en cada caso.

Las técnicas de ***prompting* activo** (*active prompting*) nacen como una solución al reto de adaptar los LLM a una amplia variedad de tareas de razonamiento. Este enfoque tiene como objetivo mejorar el rendimiento de los modelos en tareas complejas de respuesta a preguntas mediante el uso de *prompts* con ejemplos específicos por tarea que incorporan razonamiento de tipo *chain-of-thought* (Diao *et al.*, 2024).

3.5. Control del objetivo y de la salida

Las técnicas bajo esta categoría están diseñadas para mejorar la **precisión** de los LLM y fomentar **respuestas orientadas a metas concretas**. Estas técnicas distinguen entre distintos tipos de información y alinean las salidas del modelo con objetivos claramente definidos (Fagbohun *et al.*, 2024). Al establecer restricciones explícitas sobre el formato, la extensión o el propósito de la respuesta, estas técnicas reducen la ambigüedad y aumentan la relevancia de los resultados generados.

Entre las técnicas que podemos distinguir en esta categoría encontramos: *rephrase and respond (RaR)*, *show-me vs tell-me*, *target-your-response (TAR)*, *prompt macros*, *end-goal planning* y *constrained vocabulary prompting*.

La **técnica de reformular y responder** (*rephrase and respond* o RaR) busca que los LLM reformulen y amplíen la pregunta original dentro de un mismo *prompt* antes de generar la respuesta, lo que contribuye a una mejor comprensión de la tarea y a una mayor precisión en las salidas (Deng *et al.*, 2023).

El ***prompting* de "muéstrame" frente a "dímelo"** (*show-me vs tell-me*) distingue entre solicitar al modelo que "muestre" un concepto, por ejemplo, mediante diagramas o demostraciones, o que lo "explique" mediante una descripción textual (Perez *et al.*, 2021).

> **Ejemplo**
> Se puede pedir al modelo que muestre las fases de un plan de preservación digital mediante una lista estructurada o diagrama (*"muéstrame"*) o que explique de forma narrativa los objetivos y decisiones clave de cada fase (*"explícame"*), adaptando la representación al perfil del destinatario.

El ***prompting* orientado a la respuesta** (*target-your-response* o TAR) consiste en definir explícitamente el objetivo y el formato de la respuesta esperada. Esta técnica ayuda a enfocar la salida del modelo en información relevante y concisa (Zhao *et al.*, 2021).

> **Ejemplo**
> Se puede pedir al modelo:
> *Proporciona una definición de cuatro líneas sobre qué es el control de autoridades en bibliotecas, dirigida a estudiantes de primer curso universitario.*

Las **macros**[13] **de *prompts*** (*prompt macros*) integran múltiples consultas o instrucciones dentro de una única instrucción orientadas a un objetivo final amplio, pero bien delimitado. Este enfoque permite abordar tareas complejas de manera estructurada sin necesidad de múltiples interacciones separadas.

> **Ejemplo**
> *"Elabora una guía introductoria en español para estudiantes de grado sobre citación académica. Debe incluir: (1) qué es citar y por qué, (2) citación vs bibliografía, (3) citas directas e indirectas con ejemplos, (4) errores frecuentes, (5) ejemplos. Usa el estilo [APA 7 / MLA / Chicago] y limita la guía a [X] palabras."*.

La instrucción anterior condensa implícitamente múltiples microconsultas: qué es una cita, por qué se cita, tipos de citas, ejemplos de citas... El modelo decide de forma autónoma que subtareas abordar, en qué orden, con qué nivel de detalle... Es reutilizable porque solo se precisa cambiar variables: estilo, audiencia, extensión, idioma, etc.

[13] En informática, una macro es una instrucción o conjunto de instrucciones predefinidas que se reutilizan para automatizar tareas repetitivas. La idea central es encapsular una secuencia de acciones, parametrizarla si es necesario y reutilizarla de forma consistente. Aplicado al ámbito del *prompting*, surge para describir plantillas de *prompts* estructuradas y reutilizables que encapsulan: un rol o persona, una estructura de razonamiento, restricciones de formato, y variables que pueden cambiar.

El ***prompting* orientado a una meta final** (*end-goal planning*) también utiliza prompts amplios, pero se diferencia en que el objetivo final está explícitamente definido como un resultado concreto que debe alcanzarse. El modelo no solo debe responder, sino planificar y orientar sus respuestas hacia la consecución de ese objetivo final, manteniendo la coherencia entre las distintas partes de la salida.

> **Ejemplo**
> Cuando se solicita:
> *Redacta un documento de instrucciones que permita a un estudiante universitario elaborar correctamente la sección de referencias bibliográficas de un trabajo académico, de modo que pueda aplicar el procedimiento paso a paso sin necesitar aclaraciones adicionales.*

El objetivo final está explícitamente formulado: permitir que el estudiante actúe de forma autónoma. Las subtareas están subordinadas al cumplimiento del objetivo final.

El ***prompting* con vocabulario restringido** (*constrained vocabulary prompting*) implica restringir la respuesta del modelo a un conjunto específico de palabras o a un vocabulario definido. Esta técnica impone limitaciones explícitas a la salida deseada del modelo, garantizando que el contenido generado se ajuste a un léxico predefinido.

Al restringir el vocabulario, se obtiene un mayor control sobre el proceso de generación del lenguaje, lo que resulta especialmente útil en escenarios donde la precisión, la adherencia a una terminología específica o la evitación de lenguaje sensible o inapropiado son de suma importancia.

> **Ejemplo**
> Al desarrollar un asistente virtual para una biblioteca universitaria, se puede instruir al modelo: *responde a las consultas de los usuarios utilizando únicamente terminología bibliotecaria básica y evita anglicismos o jerga técnica.*

Este enfoque asegura respuestas comprensibles para público general sin perder corrección terminológica.

> **Ejemplo**
> Para contenidos dirigidos a personas con dificultades de comprensión lectora, se puede pedir, entre otras: *redacta el texto usando frases cortas y un vocabulario común, evitando tecnicismos y abreviaturas.*

En este caso el control léxico contribuye a mejorar la accesibilidad del contenido.

3.6. Código, herramientas y formalización

Esta dimensión agrupa técnicas de *prompting* orientadas a aprovechar las capacidades de los LLM para **razonar mediante estructuras computacionales** y producir **código ejecutable**, ya sea como medio para resolver una tarea o como resultado final esperado. A diferencia de las técnicas centradas exclusivamente en el razonamiento lingüístico, estos enfoques trasladan parcial o totalmente la carga inferencial al lenguaje formal del código, que ofrece mayor precisión, menor ambigüedad y una estructura lógica explícita. Entre las técnicas que podemos distinguir en esta categoría encontramos: *code prompting* y *prompt to code*.

El ***prompting* basado en código** (*code prompting*) es una técnica que transforma las tareas formuladas en lenguaje natural en código estructurado, lo que permite interactuar directamente con LLM de texto y código sin necesidad de ejecutar el código de manera externa (Puerto *et al.*, 2024).

La **conversión de *prompts* en código** (*prompt to code*) consiste en solicitar explícitamente la generación de código que cumpla con determinados requisitos funcionales (Chen *et al.*, 2023).

> **Ejemplo**
> Pedir al modelo que genere una función que convierta fechas bibliográficas en distintos formatos (por ejemplo, DD/MM/AAAA, AAAA-MM-DD, texto libre) a un formato normalizado ISO 8601,[14] especificando claramente los formatos de entrada aceptados y el formato de salida esperado.

3.7. Dimensión afectiva y estilística

El ***prompting* emocional** (*emotion prompting*) añade un estímulo o encuadre emocional a una instrucción (por ejemplo, urgencia, importancia, responsabilidad, empatía) para modular el comportamiento del modelo: suele buscar respuestas más cuidadas, completas, "atentas" a matices, o con mayor esfuerzo aparente en tareas de razonamiento o redacción. No se trata de hacer que el modelo "sienta", pues esto es imposible, sino en cambiar el contexto lingüístico y, con ello, el estilo y, en ocasiones, el desempeño (Kuka, 2024). El esquema básico es *[Prompt] [estímulo emocional]*.

> **Ejemplo**
> - *Quiero una respuesta especialmente rigurosa; si hay supuestos, decláralos explícitamente.*
> - *Es un tema sensible; responde con empatía y sin juicios.*

[14] Norma internacional para la representación no ambigua de fechas y horas en formatos legibles por personas y máquinas. https://en.wikipedia.org/wiki/ISO_8601

3.8. Multimodalidad e interdisciplinariedad

Las técnicas multimodales y transdisciplinarias integran **múltiples modos de entrada** y **diversos dominios de conocimiento** con el fin de ampliar la versatilidad de los LLM y extender sus aplicaciones a escenarios contextualmente complejos. Estas técnicas reflejan la creciente capacidad de los modelos para procesar y combinar información procedente de diferentes fuentes y disciplinas (Fagbohun *et al.*, 2024).

Entre las técnicas que podemos distinguir en esta categoría encontramos: *multimodal prompting*, *visual prompting*, *cross-disciplinary prompting*, *historical context prompting* y *modular prompting*.

El ***prompting* multimodal** combina diferentes modalidades de entrada, como texto e imágenes, para guiar la generación de respuestas del modelo. Este enfoque permite enriquecer el contexto y mejorar la expresividad de las salidas generadas (Bang *et al.*, 2023; Lee *et al.*, 2023).

> **Ejemplo**
> Un usuario proporciona una captura de pantalla del web de una biblioteca y pide al modelo que identifique posibles problemas de accesibilidad visibles (contraste de color, jerarquía visual, tamaño de texto) y sugiera mejoras preliminares basadas en la observación visual.

El ***prompting* interdisciplinar** implica la combinación de conocimientos y enfoques procedentes de múltiples disciplinas para abordar una consulta o tarea determinada. Esta técnica permite generar explicaciones o soluciones que integran perspectivas diversas.

> **Ejemplo**
> *Describe la preservación digital utilizando analogías de la ecología, comparando los ecosistemas naturales con los ecosistemas digitales*.
> Esto ayuda a entender conceptos como sostenibilidad, obsolescencia tecnológica y equilibrio entre acceso y conservación.
> *Explica qué son los metadatos recurriendo a conceptos de la lingüística, como la gramática o la sintaxis*
> Esto permite presentar los metadatos como un sistema de reglas que da sentido y estructura a los documentos, facilitando su interpretación y recuperación.

Las **técnicas de *prompting*** con contexto histórico, visual y modular se centran en la incorporación de contexto histórico, elementos visuales y construcciones modulares dentro de los *prompts* (Liu *et al.*, 2023b). Un *prompt* con contexto histórico puede solicitar al modelo que responda conforme a un entorno o referencia histórica específica, mientras que el *prompting* visual puede implicar el uso de imágenes para guiar las respuestas del

modelo, y el modular aprovecha estructuras basadas en componentes para abordar consultas complejas.

> **Ejemplo**
> *Describe el concepto de acceso abierto como lo entendería un editor académico de la década de 1970.*
> El modelo ajusta su explicación teniendo en cuenta el sistema editorial predominante en ese periodo y las limitaciones tecnológicas del momento.

3.9. Creatividad y generación abierta

Las técnicas **creativas** y **generativas** permiten a los LLM producir contenido creativo y suscitar **respuestas diversas**, **innovadoras** y **provocadoras de reflexión**. Mediante el empleo de una variedad de estrategias de *prompting*, que van desde el fomento de la ambigüedad hasta la imposición de restricciones léxicas, estas técnicas amplían las capacidades de los LLM en tareas creativas y abren nuevas vías para su aplicación en dominios como la narración, la generación de contenidos educativos y la escritura creativa. (Fagbohun *et al.*, 2024).

Entre las técnicas que podemos distinguir en esta categoría encontramos: *ambiguous prompting*, *directional stimulus prompting*, *flipped interaction prompting* y *grammar correction* (no puramente mecánica).

El ***prompting* ambiguo** (*ambiguous prompting*) emplea deliberadamente instrucciones vagas o abiertas para fomentar una gama más amplia de respuestas posibles. Al reducir el nivel de especificidad, esta técnica estimula la creatividad y la exploración de ideas por parte del modelo.

> **Ejemplo**
> *Describe una biblioteca del futuro.*
> Esto da lugar a respuestas muy distintas según el énfasis que el modelo otorgue a la tecnología, los espacios, los servicios o la relación con los usuarios.
> Pedir: *Reflexiona sobre la importancia de saber buscar información.*
> Permite interpretaciones que pueden ir desde lo práctico (estrategias de búsqueda) hasta lo crítico (desinformación, pensamiento crítico).

El ***prompting* con estímulos direccionales** utiliza pistas o estímulos direccionales para orientar al modelo hacia un resultado deseado sin imponer una solución completamente definida. Este enfoque mantiene un equilibrio entre orientación y flexibilidad, permitiendo que el modelo conserve cierto grado de creatividad (Shum *et al.*, 2023).

Ejemplo
Al pedir un ejemplo práctico sobre evaluación de fuentes, el usuario puede señalar:
Plantea el caso desde la perspectiva de un estudiante que prepara su TFG.
Este estímulo direccional condiciona el escenario narrativo y el nivel de profundidad.

El ***prompting* de interacción invertida** invierte la dinámica convencional entre el modelo y el usuario. En lugar de que el usuario dirija la conversación, el modelo plantea preguntas o solicita aclaraciones al usuario. Al invertir los roles esperados de la interacción, el modelo guía al usuario en la creación de sus propios resultados mediante consultas dirigidas.

Ejemplo
El usuario solicita: *Guíame mediante preguntas para definir indicadores de uso de una biblioteca digital.*
El modelo comienza con:
¿Qué objetivos estratégicos quiere medir la biblioteca? y continúa con preguntas sobre métricas, fuentes de datos y periodicidad.

Los ***prompts* de corrección gramatical** son instrucciones específicas dadas al modelo para identificar y corregir errores gramaticales o inconsistencias en el texto proporcionado por el usuario. Dado que los LLM han sido entrenados con grandes corpus de datos textuales, estos *prompts* pueden aprovechar las capacidades lingüísticas avanzadas del modelo para actuar como corrector gramatical conversacional, ofreciendo sugerencias y mejoras conforme a los requisitos de salida solicitados. Al pedir al LLM que mejore la redacción y el estilo de escritura, los usuarios pueden aumentar la calidad y claridad de su comunicación escrita y adaptar fácilmente sus textos a distintos usos y contextos.

Ejemplo
Un usuario ha preparado un procedimiento interno y solicita:
Corrige la gramática y mejora la redacción de este documento para que sea claro y coherente, pero sin cambiar la estructura ni el sentido original.
El modelo actúa como revisor lingüístico, no como redactor del texto.
Un usuario redacta una nota dirigida a usuarios de la biblioteca y pide: *Revisa el texto para asegurar un lenguaje correcto, accesible y profesional, evitando tecnicismos innecesarios.*
El modelo ajusta el tono y la gramática al público objetivo definido.
Un usuario ha redactado una guía rápida de uso del catálogo y pide: *Corrige la ortografía, la gramática y revisa la claridad del*

texto para que sea comprensible para público general, pero con un tono institucional.
El modelo ajusta el lenguaje respetando el equilibrio entre claridad y formalidad.

Recomendaciones finales

A continuación, se recogen algunas recomendaciones finales que redundan en aspectos comentados a lo largo del documento:

- Estandariza plantillas de *prompts* para tareas recurrentes e incorpora siempre objetivo, contexto mínimo, restricciones y formato de salida.
- Define el rol y las expectativas respecto a las características de las respuestas que esperas.
- Trabaja de forma incremental. Empieza con *prompts* simples, introduce cambios uno a uno y comparar resultados para entender qué mejora realmente el rendimiento.
- Prioriza la verificabilidad. Pide justificación, solicita fuentes y recursos adicionales para verificar la corrección de las respuestas, delimita el uso de fuentes y aplica estrategias de verificación / autorreflexión cuando la precisión sea crítica.
- Cuida la higiene de datos. No incluyas información sensible, anonimizar o seudonimizar y comparte únicamente el fragmento necesario (especialmente en textos e imágenes).
- Alinea técnica y finalidad. Elege técnicas de *prompting* según el tipo de problema (razonamiento, control de la salida, fiabilidad, diálogo, etc.) y no por "moda" o por preferencias estilísticas.

Conclusiones

Este informe ha sistematizado un conjunto amplio de recomendaciones, métodos y técnicas de *prompting* orientadas a mejorar el uso de los modelos de lenguaje en contextos académicos y profesionales. Como se ha mencionado en diversos apartados a lo largo del documento, la calidad de las respuestas no depende de una única técnica aislada, sino del acierto en la combinación de distintos elementos de diseño, tales como la claridad del *prompt*, la integración de una contextualización suficiente, la delimitación de restricciones, la especificación del formato de salida, la descomposición de tareas cuando estas son complejas o la aplicación de mecanismos de verificación cuando la fiabilidad resulta crítica. En este sentido, las buenas prácticas generales y las técnicas específicas descritas a lo largo del documento no deben entenderse como enfoques excluyentes, sino como estrategias plenamente compatibles entre sí, que pueden y deben combinarse en función del objetivo perseguido. Desde esta perspectiva, un *prompt* efectivo no es necesariamente el más largo, el más complejo o el que incorpora más técnicas, sino aquel que selecciona y articula de forma coherente los componentes

realmente necesarios para cada tarea. Así, en muchas situaciones bastará con un *prompt* breve, pero claro, bien contextualizado y con un formato de salida definido, mientras que, en otras, será conveniente añadir ejemplos, instrucciones paso a paso, estrategias de autorreflexión, mecanismos de contraste o indicaciones explícitas para verificar fuentes y supuestos.

Mejorar la calidad de los *prompts* eficaz exige una lógica de experimentación ante la imposibilidad de conocer por completo el funcionamiento interno de unos sistemas que, pese a contar ya con abundante documentación y buenas prácticas, siguen siendo en gran medida opacos por su propia arquitectura de caja negra. Diseñar buenos *prompts* implica probar, comparar, ajustar e iterar. En la práctica, esto supone comenzar con formulaciones simples, introducir cambios de manera incremental, observar el efecto de cada modificación y conservar aquellas decisiones que mejoran realmente el rendimiento para una tarea concreta. No existe un *prompt* universalmente óptimo, sino que su eficacia depende del tipo de problema, del dominio, del modelo empleado y del grado de precisión o creatividad que se requiera.

Del mismo modo, conviene insistir en que un *prompt* de calidad no se limita a obtener respuestas plausibles, fluidas o bien redactadas, sino respuestas que puedan ser examinadas críticamente. De ahí la importancia de priorizar la verificabilidad a través de la solicitud de justificaciones, fuentes, delimitando marcos de referencia, o solicitando que se indiquen limitaciones en aquellas situaciones en las que el modelo no pueda calcular, inferir o afirmar algo con suficiente base.

Referencias

Adamska, Marta, Smirnova, Daria, Nasiri, Hamid, Yu, Zhengxin, Garraghan, Peter (2025). Green prompting. https://doi.org/10.48550/arXiv.2503.10666

Bahng, Hyojin, Jahanian, Ali, Sankaranarayanan, Swami, Isola, Phillip (2022). Exploring visual prompts for adapting large-scale models. https://doi.org/10.48550/arXiv.2203.17274

Bang, Yejin, Cahyawijaya, Samuel, Lee, Nayeon, *et al.* (2023). A multitask, multilingual, multimodal evaluation of ChatGPT on reasoning, hallucination, and interactivity. In *Proceedings of the 13th International Joint Conference on Natural Language Processing and the 3rd Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics* (pp. 675–718). https://doi.org/10.18653/v1/2023.ijcnlp-main.45

Besta, Maciej, Blach, Nils, Kubicek, Ales, *et al.* (2023). Graph of thoughts: Solving elaborate problems with large language models. https://doi.org/10.1609/aaai.v38i16.29720

Brown, Tom B., Mann, Benajmin, Ryder, Nick, *et al.* (2020). Language models are few-shot learners. In *NIPS'20: Proceedings of the 34th International Conference on Neural Information Processing Systems* (pp. 1877–1900). https://doi.org/10.48550/arXiv.2005.14165

Chang, Edward (2023). Prompting large language models with the socratic method. In *2023 IEEE 13th Annual Computing and Communication Workshop and Conference (CCWC)* (pp. 351–360). https://doi.org/10.48550/arXiv.2303.08769

Chen, Eason, Wang, Danyang, Xu, Luyi, Cao, Chen, Fang, Xiao, & Lin, Jionghao (2024). A systematic review on prompt engineering in large language models for K-12 STEM education. https://doi.org/10.48550/arXiv.2410.11123

Chia, Yew Ken, Chen, Guizhen, Tuan, Luu Anh, Poria, Soujanya, & Bing, Lidong (2023). Contrastive chain-of-thought prompting. https://doi.org/10.48550/arXiv.2311.09277

Chowdhery, Aakanksha, Narang, Sharan, Devlin, Jacob, *et al.* (2023). PaLM: Scaling language modeling with pathways. *Journal of Machine Learning Research, 24*(240), 1–113. https://doi.org/10.48550/arXiv.2204.02311

Claude (2026). Use XML tags to structure your prompts. In Claude API docs. https://platform.claude.com/docs/en/build-with-claude/prompt-engineering/use-xml-tags

Comisión Europea (2019). Directrices éticas para una IA fiable. https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai

Deng, Yihe, Zhang, Weitong, Chen, Zixiang, & Gu, Quanquan (2023). Rephrase and respond: Let large language models ask better questions for themselves. https://doi.org/10.48550/arXiv.2311.04205

Desmond, Michael, & Brachman, Michelle (2024). Exploring prompt engineering practices in the enterprise. https://doi.org/10.48550/arXiv.2403.08950

Devlin, Jacob, Chang, Ming-Wei, Lee, Kenton, Toutanova, Kristina (2018). BERT: Pre-training of deep bidirectional transformers for language understanding. https://doi.org/10.48550/arXiv.1810.04805

Diao, Shizhe, Wang, Pengcheng, Lin, Yong, & Zhang, Tong (2023). Active prompting with chain-of-thought for large language models. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics* (pp. 1330–1350). https://doi.org/10.18653/v1/2024.acl-long.73

DiCuffa, Sophia, Zambrana, Amanda, Yadav, Priyanshi, Madiraju, Sashidhar, Suman, Khushi, & Alomar, Eman (2025). Exploring prompt patterns in AI-assisted code generation: Towards faster and more effective developer-AI collaboration. In *2025 IEEE 4th International Conference on Computing and Machine Intelligence (ICMI)* (pp. 1–7). https://doi.org/10.1109/ICMI65310.2025.11141320

Dong, Qingxiu, Li, Lei, Dai, Damai, *et al.* (2024). A survey for in-context learning. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing* (pp. 1107–1128). https://doi.org/10.18653/v1/2024.emnlp-main.64

Dhuliawala, Shehzaad, Komeili, Mojtaba, Xu, Jing, Raileanu, Roberta, Li, Xian, Celikyilmaz, Asli, & Weston, Jason (2024). Chain-of-verification reduces hallucination in large language models. In *Findings of the Association for Computational Linguistics: ACL 2024* (pp. 3563–3578). https://doi.org/10.18653/v1/2024.findings-acl.212

Fagbohun, Oluwole, Harrison, Rachel M., & Dereventsov, Anton (2023). An empirical categorization of prompting techniques for large language models: A practitioner's guide. *Journal of Artificial Intelligence, Machine Learning and Data Science, 1*(4), 1–11. https://doi.org/10.51219/JAIMLD/Oluwole-Fagbohun/15

Fungwacharakorn, Wachara, Thanh, Nguyen Ha, Myo Zin, May, & Satoh, Ken (2024). Layer-of-thoughts prompting (LoT): Leveraging LLM-based retrieval with constraint hierarchies. https://doi.org/10.48550/arXiv.2410.12153

Garcia, Enio Santan Junior, Benjamin, Gabriel, Araujo, Melissa, *et al.* (2025). Which prompting technique should I use? An empirical investigation of prompting techniques for software engineering tasks. https://doi.org/10.48550/arXiv.2506.05614

Gemini (2025). Prompt design strategies. In Gemini API. https://ai.google.dev/gemini-api/docs/prompting-strategies

Greyling, Cobus (2023). Chain-of-note (CoN) retrieval for LLMs. Medium. https://cobusgreyling.medium.com/chain-of-note-con-retrieval-for-llms-763ead1ae5c5

Gu, Heng, Degachi, Chadha, Genç, Uğur, Chandrasegaran, Senthil, & Verma, Himanshu (2023). On the effectiveness of creating conversational agent personalities through prompting. https://doi.org/10.48550/arXiv.2310.11182

Gutheil, Niklas, Mayer, Valentin, Müller, Leopold, Römmelt, Jörg, & Kühl, Niklas (2025). PromptPilot: Improving human-AI collaboration through LLM-enhanced prompt engineering. https://doi.org/10.48550/arXiv.2510.00555

Harrison, Rachel M., Dereventsov, Anton, & Bibin, Anton (2023). Zero-shot recommendations with pre-trained large language models for multimodal nudging. https://doi.org/10.48550/arXiv.2309.01026

Hewing, Michael, & Leinhos, Vincent (2024). The prompt canvas: A literature-based practitioner guide for creating effective prompts in large language models https://doi.org/10.48550/arXiv.2412.05127

Hu, Hanxu, Lu, Hongyuan, Zhang, Huajian, Song, Yun-Ze, Lam, Wai, & Zhang, Yue (2023). Chain-of-symbol prompting elicits planning in large language models. https://doi.org/10.48550/arXiv.2305.10276

Jiang, Albert Q., Sablayrolles, Alexandre, Mensch, Arthur, *et al.* (2023). Mistral 7B. https://doi.org/10.48550/arXiv.2310.06825

Kasneci, Enkelejda, Seßler, Kathrin, Küchemann, Stefan, *et al.* (2023). Chatgpt for good? on opportunities and challenges of large language models for education. *Learning and Individual differences, 103*(102274). https://doi.org/10.1016/j.lindif.2023.102274

Kojima, Takeshi, Gu, Shixiang Shane, Reid, Machel, & Matsuo, Yutaka, & Iwasawa, Yusuke (2023). Large language models are zero-shot reasoners. https://doi.org/10.48550/arXiv.2205.11916

Kuka, Valeriia (2024). Emotion prompting. In *Learn prompting*. https://learnprompting.org/docs/basics/prompt_structure

Kuka, Valeriia (2025). Basic prompt structure and key parts. In *Learn prompting*. https://learnprompting.org/docs/basics/prompt_structure

Lee, Yi-Lun, Tsai, Yi-Hsuan, Chiu, Wei-Chen, & Lee, Chen-Yu (2023). Multimodal prompting with missing modalities for visual recognition. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 14943–14952). https://openaccess.thecvf.com/content/CVPR2023/papers/Lee_Multimodal_Prompting_With_Missing_Modalities_for_Visual_Recognition_CVPR_2023_paper.pdf

Leviathan, Yaniv, Kalman, Matan, & Matias, Yossi (2025). Prompt Repetition Improves Non-Reasoning LLM. https://doi.org/10.48550/arXiv.2512.14982

Lewis, Patrick, Perez, Ethan, Piktus, Aleksandra, *et al.* (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. In *NIPS'20: Proceedings of the 34th International Conference on Neural Information Processing Systems* (pp. 9459–9474). https://dl.acm.org/doi/abs/10.5555/3495724.3496517

Li, Xingxuan, Zhao, Ruochen, Chia, Yew Ken, Ding, Bosheng, Joty, Shafiq, Poria, Soujanya, & Bing, Lidong (2023a). Chain-of-knowledge: Grounding large language models via dynamic knowledge adapting over heterogeneous sources. https://doi.org/10.48550/arXiv.2305.13269

Li, Cheng, Wang, Jindong, Zhang, Yixuan, *et al.* (2023b). Large language models understand and can be enhanced by emotional stimuli. https://doi.org/10.48550/arXiv.2307.11760

Liu, Shixuan, Peng, Chen, Wang, Chao, Chen, Xiangyan, Song, Shuangyong (2023a). icsBERTs: Optimizing pre-trained language models in intelligent customer service.

Procedia Computer Science, 222, 127–136. https://doi.org/10.1016/j.procs.2023.08.150

Liu, Pengfei, Yuan, Weizhe, Fu, Jinlan, Jiang, Zhengbao, Hayashi, Hiroaki, & Neubig, Graham (2023b). Pre-train, prompt, and predict: A systematic survey of prompting methods in natural language processing. *ACM Computing Surveys, 55*(9), 1–35. https://doi.org/10.1145/3560815

Liu, Xinyue, Mireshghallah, Niloofar, Ginsburg, Jane C., Chakrabarty, Tuhin (2026). Alignment whack-a-mole: Finetuning activates verbatim recall of copyrighted books in large language models. https://doi.org/10.48550/arXiv.2603.20957

Long, Jieyi (2023). Large language model guided tree-of-thought. https://doi.org/10.48550/arXiv.2305.08291

Lyu, Qing, Havaldar, Shreya, Stein, Adam, Zhang, Li, Rao, Delip, Wong, Eric, Apidianaki, Marianna, & Callison-Burch, Chris (2023). Faithful chain-of-thought reasoning. https://doi.org/10.48550/arXiv.2301.13379

Ma, Pingchuan, Li, Zongjie, Sun, Ao, & Wang, Shuai (2023). "Oops, Did I just say that? Testing and repairing unethical suggestions of large language models with suggest-critique-reflect process. https://doi.org/10.48550/arXiv.2305.02626

Madaan, Aman, Tandon, Niket, & Gupta, Prakhar, *et al.* (2023). Self-refine: Iterative refinement with self-feedback. https://doi.org/10.48550/arXiv.2303.17651

MacCallum, & Noah, Julian (2025). GPT-4.1 Prompting guide. In Cookbook: Recipes, guides, and notebooks to help you build with OpenAI models. https://developers.openai.com/cookbook/examples/gpt4-1_prompting_guide

Ning, Xuefei, Lin, Zinan, Zhou, Zixan, Yang, Zifu, & Wang, Yu (2023). Skeleton-of-thought: Large language models can do parallel decoding. https://doi.org/10.48550/arXiv.2307.15337

NIST, National Institute of Standards and Technology (2023). Artificial intelligence risk management framework (AI RMF 1.0). https://doi.org/10.6028/NIST.AI.100-1

O'Neil, Cathy (2017). *Armas de destrucción matemática: Cómo el big data aumenta la desigualdad y amenaza la democracia*. Capitan Swing.

Open AI (2025). Best practices for prompt engineering with the OpenAI API. https://help.openai.com/en/articles/6654000-best-practices-for-prompt-engineering-with-the-openai-api

Ouyang, Long, Wu, Jeff, Jiang, Xu, *et al.* (2022). Training language models to follow instructions with human feedback. In Advances in Neural Information Processing Systems 35 (NeurIPS 2022). https://doi.org/10.48550/arXiv.2203.02155

OWASP (2025). OWASP top 10 for LLM applications 2025. https://owasp.org/www-project-top-10-for-large-language-model-applications/assets/PDF/OWASP-Top-10-for-LLMs-v2025.pdf

Paul, Debjit, Ismayilzada, Mete, Peyrard, Maxime, Borges, Breatriz, Bosselut, Antoine, West, Robert, & Faltings, Boi (2024). Refiner: Reasoning feedback on intermediate representations. In *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics* (pp. 1100–1126).

https://dlab.epfl.ch/people/west/pub/Paul-Ismayilzada-Peyrard-Borges-Bosselut-West-Faltings.pdf

Perez, Ethan, Kiela, Douwe. & Cho, Kyunghyun (2021). True few-shot learning with language models. In *NIPS'21: Proceedings of the 35th International Conference on Neural Information Processing Systems, 845* (pp. 11054–11070). https://dl.acm.org/doi/10.5555/3540261.3541106

Petroni, Fabio, Rocktäschel Tim, Lewis Patrick, Bakhtin, Anton, Wu, Yuxiang, Miller, Alexander H., & Riedel, Sebastian (2019). Language models as knowledge bases?. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing* (pp. 2463–2473). https://doi.org/10.48550/arXiv.1909.01066

Puerto, Haritz, Tutek, Martin, Aditya, Somak, Zhu, Xiaodan, & Gurevych, Iryna (2024). Code prompting elicits conditional reasoning abilities in text+code LLMs. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing* (pp. 11234–11258). https://doi.org/10.18653/v1/2024.emnlp-main.629

Radford, Alec, Wu, Jeffrey, Child, Rewon, Luan, David, Amodei, Dario, Sutskever, Ilya (2019). Language models are unsupervised multitask learners. https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf

Rahman, Arifur (2026). A systematic review of vision language models: Comprehensive analysis of architectures, applications, datasets and challenges towards robust multimodal intelligence. *Array, 30*, 100739, 1–41. https://doi.org/10.1016/j.array.2026.100739

Resnik, David B., Hosseini, Mohammad (2025). Disclosing artificial intelligence use in scientific research and publication: When should disclosure be mandatory, optional, or unnecessary?. *Accountability in Research, 33*(2), 1–13. https://doi.org/10.1080/08989621.2025.2481949

Rubin, Ohad, Herzig, Jonathan, & Berant, Jonathan (2021). Learning to retrieve prompts for in-context learning. https://doi.org/10.48550/arXiv.2112.08633

Sahoo, P., A. K. Singh, S. Saha, V. Jain, S. Mondal, and A. Chadha (2024). A systematic survey of prompt engineering in large language models: Techniques and applications. https://doi.org/10.48550/arXiv.2402.07927

Shaikh, Omar, Zhang, Hongxin, Held, William, Bernstein, Michael, & Yang, Diyi (2023). On second thought, let's not think step by step! Bias and toxicity in zero-shot reasoning. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics* (pp. 4454–4470). https://doi.org/10.18653/v1/2023.acl-long.244

Schick, Timo, & Schütze, Hinrich (2020). It's not just size that matters: small language models are also few-shot learners. https://doi.org/10.48550/arXiv.2009.07118

Shinn, Noah, Labash, Beck, & Gopinath, Ashwin (2023). Reflexion: An autonomous agent with dynamic memory and self-reflection. https://doi.org/10.48550/arXiv.2303.11366

Shum, Kashun, Diao, Shizhe, & Zhang, Tong (2023). Automatic prompt augmentation and selection with chain-of-thought from labeled data. In *Findings of the Association for Computational Linguistics: EMNLP 2023* (pp. 12113–12139). https://doi.org/10.18653/v1/2023.findings-emnlp.811

Thirunavukarasu, Arun James, Ting, Darren Shu Jeng, Elangovan, Kabilan, Gutierrez, Laura, Tan, Ting Fan, Ting, Daniel Shu Wei (2023). Large language models in medicine. *Nature Medicine, 29*(8), 1930–1940. https://doi.org/10.1038/s41591-023-02448-8

Thoppilan, Romal, De Freitas, Daniel, Hall, Jamie, *et al.* (2022). LaMDA: Language models for dialog applications. https://doi.org/10.48550/arXiv.2201.08239

Tokayev, Kassym-Jomart (2023). Ethical implications of large language models: A multidimensional exploration of societal, economic, and technical concerns. International *Journal of Social Analytics, 8*(9), 17-33. https://norislab.com/index.php/ijsa/article/view/42

Torres-Salinas, Daniel (2025). Primeros pasos con ChatGPT e ingeniería de prompts. https://doi.org/10.5281/zenodo.15260566

Touvron, Hugo, Lavril, Thibaut, Izacard, Gautier, *et al.* LLaMA: Open and efficient foundation language models. https://doi.org/10.48550/arXiv.2302.13971

Wang, Xuezhi, Wei, Jason, Schuurmans, Dale, *et al.* (2023). Self-consistency improves chain of thought reasoning in language models. https://doi.org/10.48550/arXiv.2203.11171

Wang, Yuqing, & Zhao, Yun (2024). Metacognitive prompting improves understanding in large language models. In *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies* (pp. 1914–1926). https://aclanthology.org/2024.naacl-long.106.pdf

Wang, Ming, Liu, Yuanzhong, Liang, Xiaoyu, Huang, Yijie, *et al.* 2024. Minstrel: Structural prompt generation with multi-agents coordination for non-AI experts. https://doi.org/10.48550/arXiv.2409.13449

Vaswani, Ashish, Shazeer, Noam, Parmar, Niki, *et al.* (2017). Attention is all you need. In NIPS'17: *Proceedings of the 31st International Conference on Neural Information Processing Systems* (pp. 6000–6010). https://doi.org/10.48550/arXiv.1706.03762

Wei, Jason, Wang, Xuezhi, Schuurmans, Dale, Bosma, Maarten, Ichter, Brian, Xia, Fei, Chi, Ed, Le, Quoc, & Zhou, Denny (2022). Chain-of-thought prompting elicits reasoning in large language models. In *NIPS'22: Proceedings of the 36th International Conference on Neural Information Processing Systems* (pp. 24824–2483). https://dl.acm.org/doi/10.5555/3600270.3602070

Wei, Jing, Kim, Sungdong, Jung, Hyunhoon, & Kim, Young-Ho (2023). Leveraging large language models to power chatbots for collectiong user self-reported data. *Proceedings of the ACM on Human-Computer Interaction, 8*(87), 1–35. https://doi.org/10.1145/3637364

White, Jules, Fu, Quchen, Hays, Sam, Sandborn, Michael, Olea, Carlos, Gilbert, Henry, Elnashar, Ashraf. Spencer-Smith, Jesse, & Schmidt, Douglas C. (2023). A prompt

pattern catalog to enhance prompt engineering with ChatGPT. https://doi.org/10.48550/arXiv.2302.11382

Wu, Shijie, Irsoy, Ozan, Lu, Steven, *et al.* Bloomberg GPT: A large language model for finance. https://doi.org/10.48550/arXiv.2303.17564

Xu, Frank F., Alon, Uri, Neubig, Graham, Hellendoorn Vincent, J. (2022). A systematic evaluation of large language models of code. In *Proceedings of the 6th ACM SIGPLAN International Symposium on Machine Programming 2022* (pp. 1–10). https://doi.org/10.48550/arXiv.2202.13169

Xu, Silei, Xie, Wenhao, Zhao, Lingxiao, & He, Pengcheng (2025). Chain of draft: Thinking faster by writing less. https://doi.org/10.48550/arXiv.2502.18600

Yang, Jingfeng, Jin, Hongye, Tang, Ruixian, *et al.* (2024a). Harnessing the power of LLMs in practice: A survey on ChatGPT and beyond. *ACM Transactions on Knowledge Discovery from Data, 18*(6), 1–32. https://doi.org/10.1145/3649506

Yang, Ling, Yu, Zhaochen, Zhang, Tianjun, Cao, Shiyi, Xu, Minkai, Zhang, Wentao, Gonzalez, Joseph E., & Cui, Bin (2024b) Buffer of thoughts: Thought-augmented reasoning with large language models. In *NIPS '24: Proceedings of the 38th International Conference on Neural Information Processing Systems* (pp. 113519–113544). https://dl.acm.org/doi/10.5555/3737916.3741523

Yao, Shunyu, Yu, Dian, Zhao, Jeffrey, Shafran, Izhak, Griffiths, Thomas L., Cao, Yuan, & Narasimhan, Karthik (2023). Tree of thoughts: Deliberate problem solving with large language models. https://doi.org/10.48550/arXiv.2305.10601

Ye, Xi, Iyer, Srinivassan, Celikyilmaz, Asli, Stoyanov, Ves, Durrett, Greg, & Pasunuru, Ramakanth (2022). Complementary explanations for effective in-context learning. https://doi.org/10.48550/arXiv.2211.13892

Yu, Wenhao, Zhang, Hongming, Pan, Xiaoman, Ma, Kaixin, Wang, Hongwei, & Yu, Dong (2023). Chain-of-note: Enhancing robustness in retrieval-augmented language models. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing* (pp. 14672-14685). https://doi.org/10.18653/v1/2024.emnlp-main.813

Zamfirescu-Pereira, J.D., Wong, Richmond, Y, Hartmann, Bjoern, Yang, Qian (2023). Why Johnny can't prompt: How non-AI experts try (and fail) to design LLM prompts. In *CHI '23: Proceedings of the 2023 CHI Conference on Human Factors in Computing System* (pp. 1–21). https://doi.org/10.1145/3544548.3581388

Zheng, Huaixiu Steven, Mishra, Swaroop, Chen, Xinyun, Cheng, Heng-Tze, Chi, Ed H. Le, Quoc V., & Zhou, Denny (2023). Take a step back: Evoking reasoning via abstraction in large language models. https://doi.org/10.48550/arXiv.2310.06117

Zhang, Zhuosheng, Zhang, Aston, Li, Mu, & Smola, Alex (2022). Automatic chain of thought prompting in large language models. https://doi.org/10.48550/arXiv.2210.03493

Zhang, Xinliang Frederick, Beauchamp, Nick, & Wang, Lu (2024). Narrative-of-thought: Improving temporal reasoning of large language models via recounted narratives. In *Findings of the Association for Computational Linguistics: EMNLP 2024* (pp. 16507–16530). https://doi.org/10.18653/v1/2024.findings-emnlp.963

Zhao, Tony Z., Wallace, Eric, Feng, Shi, Klein, Dan & Singh, Sameer (2021). Calibrate before use: Improving few-shot performance of language models. https://doi.org/10.48550/arXiv.2102.09690

Zhao, Wayne Xin, Zhou, Kun, Li, Junyi, *et al.* (2023a). A survey of large language models. https://doi.org/10.48550/arXiv.2303.18223

Zhao, Xufeng, Li, Mengdi, Lu, Wenhao, Weber, Cornelius, Lee, Jae Hee, Chu, Kun & Wermter, Stefan (2023b). Enhancing zero-shot chain-of-thought reasoning in large language models through logic. https://doi.org/10.48550/arXiv.2309.13339

Zhou, Yucheng, Geng, Xiubo, Shen, Tao, Tao, Chongyang, Long, Guodong, Lou, Jian-Guang, & Shen, Jianbing (2023). Thread of thought unraveling chaotic contexts. https://doi.org/10.48550/arXiv.2311.08734

Zheng, Chuanyang, Liu, Zhengying, Xie, Enze, Li, Zhenguo, & Li, Yu (2023). Progressive-hint prompting improves reasoning in large language models. https://doi.org/10.48550/arXiv.2304.09797



UNIVERSITAT DE BARCELONA